

Création et utilisation de la base de données

Laplace Immo

Contexte du projet

Se démarquer de la concurrence en créant un **modèle pour mieux prévoir le prix de vente des biens immobiliers**.

Créer une base de donnée pour **collecter toutes les transactions immobilières et foncières.**

Analyser le marché et aider les différentes agences régionales à **mieux accompagner leurs clients**.



La stratégie de sauvegarde et la conformité RGPD

Conformité au Règlement général sur la protection des données (RGPD)

Sources des données

- **INSEE** Données statistiques et géographiques sans caractère personnel direct ✅
- Données extraites du site open data des Demandes de valeurs foncières (DVF) ⚠️

Minimisation et périmètre

- Suppression des noms des personnes physiques issus des transactions DVF
- Conservation des seules données nécessaires à l'identification des biens (adresses, références géographiques)
- Absence de traitement visant l'identification des personnes

Sécurité et sauvegarde

- Sauvegardes régulières de la base de données
- Accès restreint aux données et environnement de stockage sécurisé
- Séparation entre données sources et données nettoyées / agrégées

Gouvernance et contrôle

- Vérification régulière de l'adéquation entre données conservées et finalité du traitement
- Possibilité de purge ou d'actualisation des données
- Approche conforme aux principes de minimisation et de responsabilité (RGPD)

Les données initiales

3 tables

Données	Lignes	colonnes
Des données de l'INSEE sur les communes avec des recensements de la population	34 991	9
Des données de data.gouv sur les régions, avec le référentiel géographique français, communes, unités urbaines, aires urbaines, départements, académies, régions	38 916	37
Des données extraites du site open data des Demandes de valeurs foncières (DVF)	34 169	46



Supprimer

- Donner inutiles : nom académie, etc.
- Colonnes vides
- Donné anciennes modifiées depuis
- Données identiques ou redondantes



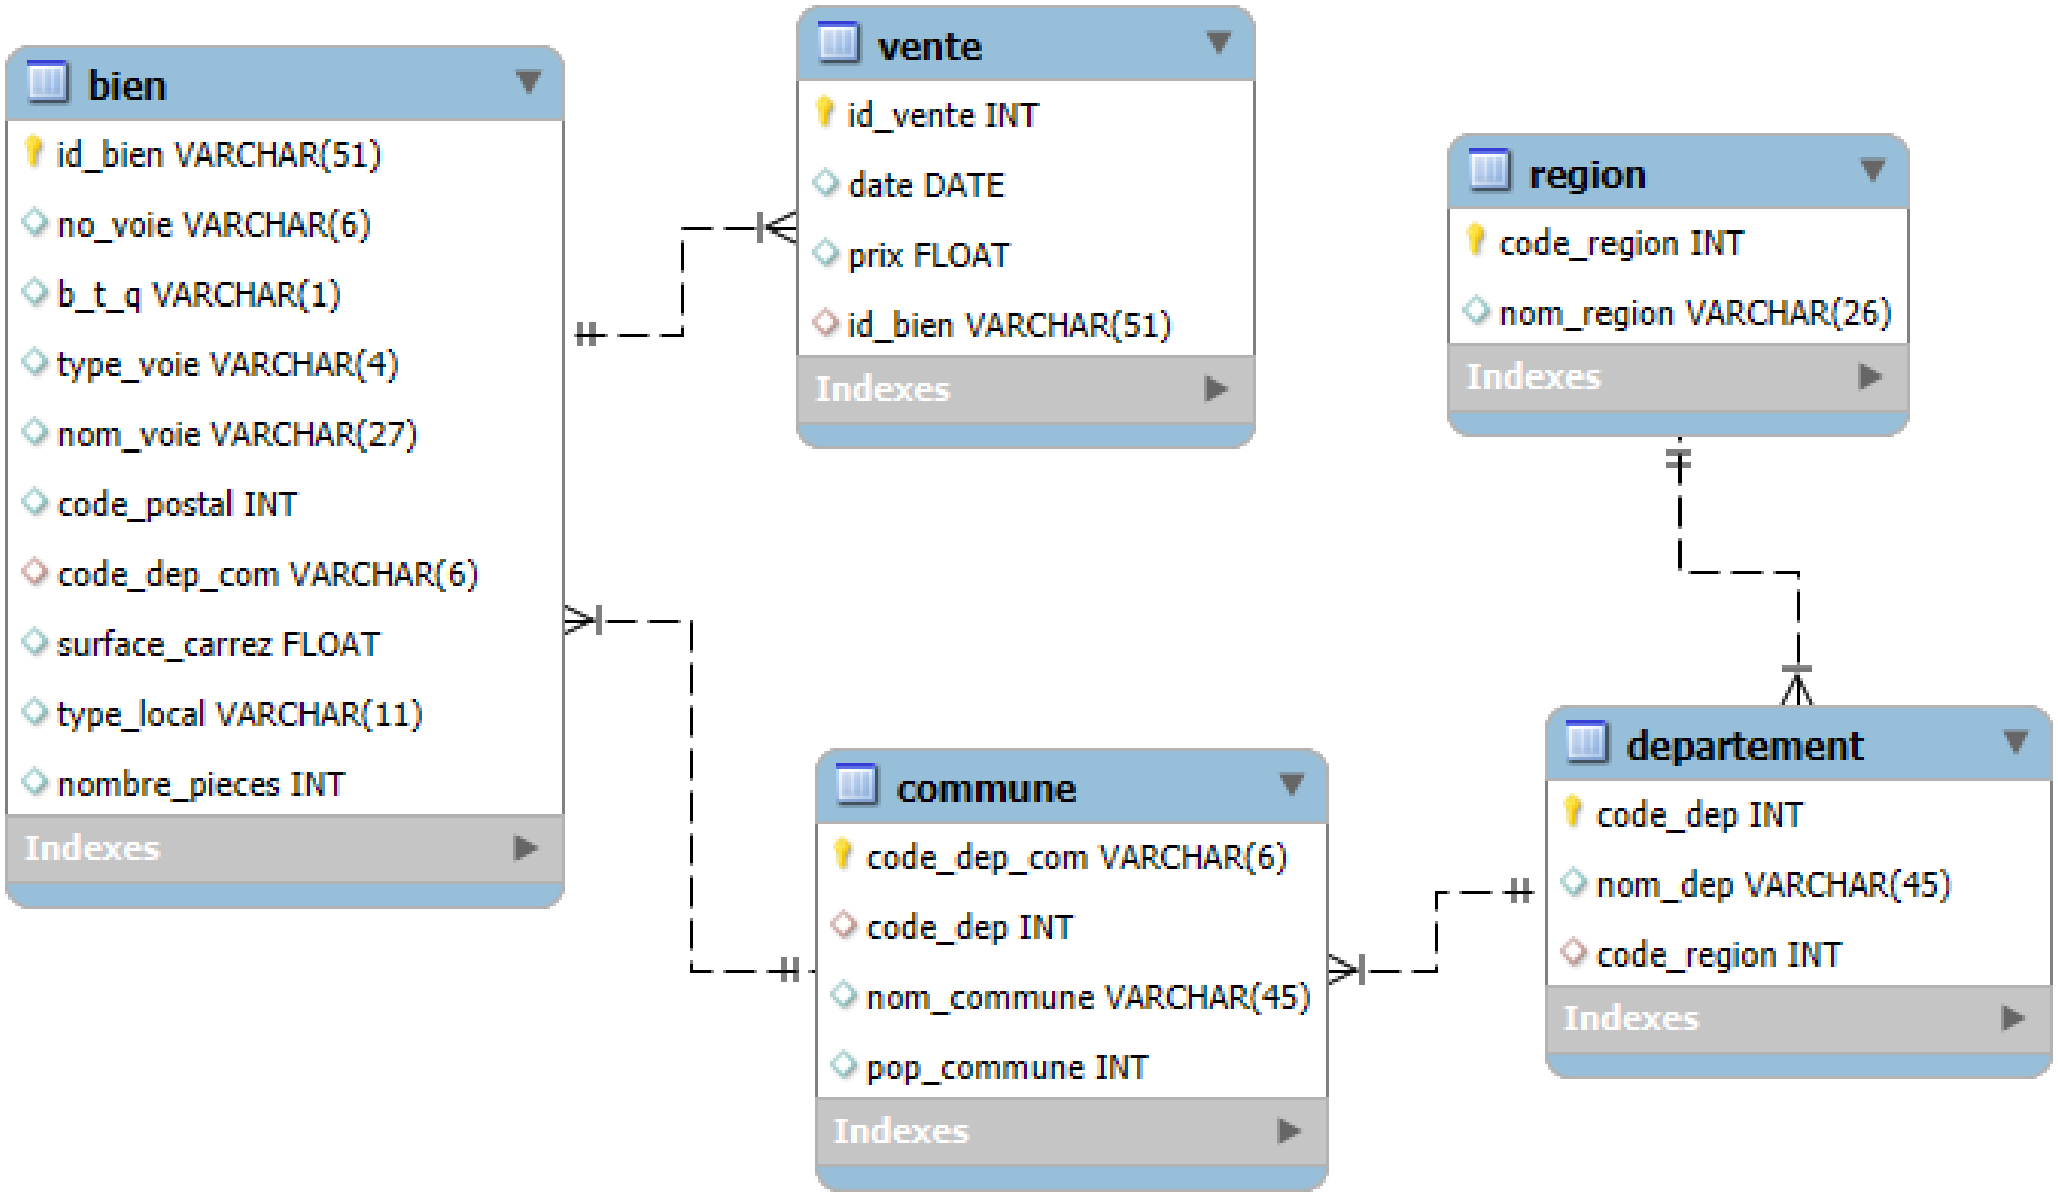
Réorganiser

- Table commune
- Diviser en deux tables: 'vente' et 'bien'
- Diviser en deux tables: 'departement' et 'region'

L’extrait du dictionnaire des données

Table		Lignes	colonnes
Ventes	Toutes les transactions: prix, date,	34 169	10
Biens	Les biens: adresse, surface, type, nombre de pièce	34 153	4
Communes	Codes et noms et population des communes	34 991	4
Départements	Nom et code des département	109	3
Régions	Nom et code des régions	19	2

Le schéma relationnel normalisé



La base de données avec les tables créées et les données chargées

Table	Column	Type
bien	id_bien	varchar(51)
bien	no_voie	varchar(6)
bien	b_t_q	varchar(1)
bien	type_voie	varchar(4)
bien	nom_voie	varchar(26)
bien	code_postal	varchar(6)
bien	code_dep_com	varchar(8)
bien	surface_carrez	float
bien	type_local	varchar(11)
bien	nombre_pieces	int
commune	code_dep_com	varchar(8)
commune	code_dep	varchar(3)
commune	nom_commune	varchar(50)
commune	pop_commune	int
departement	code_dep	varchar(3)
departement	nom_dep	varchar(50)
departement	code_region	varchar(3)
region	code_region	varchar(3)
region	nom_region	varchar(50)
vente	id_vente	int
vente	date	date
vente	prix	decimal(10,2)
vente	id_bien	varchar(55)

	nom_table	nombre_lignes
▶	bien	34153
	vente	34169
	commune	34991
	departement	109
	region	19



Requêtes SQL et résultats

1 Vente d’appartements dans tout le pays

Dans l’ensemble du pays:
31 363 appartement ont été vendus au premier semestre de 2020

Dont 15 ont été vendu 2 fois dans le semestre

```sql
select count(distinct v.id_bien) as nb_appartements
from vente v
join bien b on v.id_bien = b.id_bien
where b.type_local = 'Appartement'
and v.date between '2020-01-01' and '2020-06-30';
```

2 Vente d'appartements par région

Nombre d'appartement vendu par région au premier semestre de 2020

```
select r.code_region, r.nom_region,
count(distinct v.id_bien) as nb_appartements
from vente v
JOIN bien b on v.id_bien = b.id_bien
join commune c on c.code_dep_com = b.code_dep_com
join departement d on d.code_dep = c.code_dep
join region r on r.code_region = d.code_region
where b.type_local = 'appartement'
group by r.code_region
order by nb_appartements desc;
```

Code région	Nom de la région	Vente d'appartement
11	Ile-de-France	13988
93	Provence-Alpes-Côte d'Azur	3649
84	Auvergne-Rhône-Alpes	3253
75	Nouvelle-Aquitaine	1930
76	Occitanie	1640
52	Pays de la Loire	1356
32	Hauts-de-France	1252
44	Grand Est	983
53	Bretagne	983
28	Normandie	860
24	Centre-Val de Loire	696
27	Bourgogne-Franche-Comté	376
94	Corse	223
02	Martinique	94
04	La Réunion	44
03	Guyane	34
01	Guadeloupe	2

3 Vente d’appartements par pièce

Proportion des ventes d’appartements par le nombre de pièces.

```
select b.nombre_pieces, count(*) as nb_vente,
round(count(*)/(select count(*) as total_vente
from vente v
join bien b on b.id_bien = v.id_bien
where b.type_local = 'appartement')*100, 2)
as pourcentage
from vente v
join bien b on b.id_bien = v.id_bien
where b.type_local = 'appartement'
group by b.nombre_pieces
order by b.nombre_pieces;
```

nombre_pieces	nb_vente	pourcentage
0	30	0.10
1	6739	21.48
2	9783	31.18
3	8966	28.57
4	4460	14.21
5	1114	3.55
6	204	0.65
7	54	0.17
8	17	0.05
9	8	0.03
10	2	0.01
11	1	0.00

4 Les départements les plus chers

Liste des 10 départements **où le prix du mètre carré** est le plus élevé.

```
select d.code_dep, d.nom_dep,
round(avg(v.prix / b.surface_carrez), 2)
as prix_m2_moyen
from departement d
join commune c on d.code_dep = c.code_dep
join bien b on b.code_dep_com = c.code_dep_com
join vente v on b.id_bien = v.id_bien
group by d.code_dep
order by prix_m2_moyen desc
limit 10;
```

code_dep	nom_dep	prix_m2_moyen
75	Paris	12052.82
92	Hauts-de-Seine	7219.39
94	Val-de-Marne	5343.28
06	Alpes-Maritimes	4700.26
74	Haute-Savoie	4667.13
93	Seine-Saint-Denis	4344.78
78	Yvelines	4225.25
69	Rhône	4059.28
2A	Corse-du-Sud	4026.97
33	Gironde	3764.14

5 Prix des maison en Ile-de-France

Prix moyen du mètre carré d'une maison en Île-de-France au premier semestre de 2020 est de **3745.09 €**

```sql
select round(avg(v.prix / b.surface_carrez), 2) as prix_m2
from vente v
join bien b on b.id_bien = v.id_bien
join commune c on c.code_dep_com = b.code_dep_com
join departement d on c.code_dep = d.code_dep
join region r on r.code_region = d.code_region
where b.type_local = 'Maison'
and r.nom_region like 'Ile-de-France%';
```

6 Où sont les appartements les plus chers?

Liste des 10 appartements dont le prix de vente total a été les plus chers

```
select round(v.prix, 0) as prix,
 r.nom_region, b.surface_carrez as m2,
 b.nombre_pieces
from vente v
join bien b on b.id_bien = v.id_bien
join commune c on c.code_dep_com = b.code_dep_com
join departement d on c.code_dep = d.code_dep
join region r on r.code_region = d.code_region
order by v.prix desc
limit 10;
```

prix	nom_region	m2	nombre_pieces
9000000	Ile-de-France	9.1	1
8600000	Ile-de-France	64	3
8577713	Ile-de-France	20.55	7
7620000	Ile-de-France	42.77	2
7600000	Ile-de-France	253.3	5
7535000	Ile-de-France	139.9	4
7420000	Ile-de-France	360.95	8
7200000	Ile-de-France	595	8
7050000	Ile-de-France	122.56	7
6600000	Ile-de-France	79.38	3

7 Les ventes augmentent-ils d'un trimestre à l'autre?

Taux d'évolution du nombre de ventes entre le premier et le second trimestre de 2020 est de **3,68%**.

```
select round((vente_t2 - vente_t1)/vente_t1 * 100, 2)
as taux_évolution
from
(select count(*) as vente_t1
from vente
where date < '2020-04-01') t1,
(select count(*) as vente_t2
from vente
where date > '2020-03-31') t2;
```

8 Où sont les grands appartements les plus chers?

Le classement des régions par rapport au **prix au mètre carré** des appartement **de plus de 4 pièces**.

```
select r.nom_region,
round(avg(v.prix / b.surface_carrez), 2)
AS prix_m2_moyen
from region r
join departement d on d.code_region = r.code_region
join commune c on d.code_dep = c.code_dep
join bien b on b.code_dep_com = c.code_dep_com
join vente v on b.id_bien = v.id_bien
where b.nombre_pieces > 4
and b.type_local = 'Appartement'
group by r.nom_region
order by prix_m2_moyen desc;
```

nom_region	prix_m2_moyen
Ile-de-France	8770.44
La Réunion	3641.81
Provence-Alpes-Côte d'Azur	3587.65
Corse	3104.88
Auvergne-Rhône-Alpes	2891.38
Nouvelle-Aquitaine	2465.48
Bretagne	2412.05
Pays de la Loire	2315.76
Hauts-de-France	2189.93
Occitanie	2097.23
Normandie	2015.77
Grand Est	1540.89
Centre-Val de Loire	1453.11
Bourgogne-Franche-Comté	1251.19
Martinique	573.48

9 Quelles sont les communes les plus actives?

48 communes ont eu au moins 50 ventes au 1er trimestre 2020. Les ventes les plus nombreux sont dans les arrondissement de Paris

```
select c.nom_commune,
count(*) as nombre_vente_t1
from vente v
join bien b on v.id_bien = b.id_bien
join commune c on b.code_dep_com = c.code_dep_com
where v.date between '2020-01-01' and '2020-03-31'
group by c.code_dep_com
having count(*) >= 50
order by nombre_vente_t1 desc;
```

nom_commune	nombre_vente_t1
Paris 17e Arrondissement	228
Paris 15e Arrondissement	215
Paris 18e Arrondissement	209
Nice	173
Paris 11e Arrondissement	169
Paris 16e Arrondissement	165
Bordeaux	157
Paris 14e Arrondissement	146
Paris 20e Arrondissement	127
Nantes	119
Paris 19e Arrondissement	116
Paris 12e Arrondissement	110
Paris 10e Arrondissement	109
Grenoble	106
Angers	64
. . .	. . .
Ajaccio	54
Puteaux	53
Issy-les-Moulineaux	50

10 Différence de prix au m2 en fonction de nombre des pièces

Les **appartement** de 2 pièces coutent, au mettre carré, environ **14,16% plus chers** que les appartement de 3 pièces

```
select round((prixm2_F2-prixm2_F3)/prixm2_F3*100, 2)as diff_F2_F3
from
(select avg(v.prix/b.surface_carrez)
as prixm2_F2
from vente v
join bien b on v.id_bien = b.id_bien
where b.nombre_pieces = 2
and b.type_local = 'Appartement') F2,
(select avg(v.prix/b.surface_carrez)
as prixm2_F3
from vente v
join bien b on v.id_bien = b.id_bien
where b.nombre_pieces = 3
and b.type_local = 'Appartement') F3;
```

11 Les 3 communes des départements 6,13, 33, 59 et 69

```sql
with prix_par_commune as (
select c.code_dep, c.nom_commune,
 round(avg(v.prix), 2) as prix_moyen
from vente v
join bien b on v.id_bien = b.id_bien
join commune c on b.code_dep_com = c.code_dep_com
join departement d on d.code_dep = c.code_dep
where d.code_dep in ('06' , '13' , '33' , '59' , '69')
group by c.code_dep, c.nom_commune)
select code_dep, nom_commune, prix_moyen
from (
select code_dep, nom_commune, prix_moyen,
rank() OVER (PARTITION BY code_dep ORDER BY prix_moyen DESC) AS
rang
FROM prix_par_commune) AS result
WHERE rang <= 3 ;
```

code_dep	nom_commune	prix_moyen
06	Saint-Jean-Cap-Ferrat	968750.00
06	Eze	655000.00
06	Mouans-Sartoux	476898.10
13	Gignac-la-Nerthe	330000.00
13	Saint-Savournin	314425.00
13	Cassis	313416.88
33	Lège-Cap-Ferret	549500.64
33	Vayres	335000.00
33	Arcachon	307435.93
59	Bersée	433202.00
59	Cysoing	408550.00
59	Halluin	322250.00
69	Ville-sur-Jarnioux	485300.00
69	Lyon 2e Arrondissement	455217.27
69	Lyon 6e Arrondissement	426968.25

12 Les communes les plus actives par rapport à leur taille

Liste des 20 communes avec **le plus de transactions pour 1000 habitants** pour les communes de **plus de 10 000 habitants**

```
select c.nom_commune,
round((count(*)/c.pop_commune)*1000 ,2)
as vente_1000
from vente v
join bien b on v.id_bien = b.id_bien
join commune c on b.code_dep_com = c.code_dep_com
where c.pop_commune>10000
group by c.code_dep_com
order by vente_1000 desc
limit 20;
```

nom_commune	vente_1000
Paris 2e Arrondissement	5.84
Paris 1er Arrondissement	4.92
Paris 3e Arrondissement	4.69
Arcachon	4.62
La Baule-Escoublac	4.58
Paris 4e Arrondissement	4.08
Roquebrune-Cap-Martin	3.99
Paris 8e Arrondissement	3.83
Sanary-sur-Mer	3.50
La Londe-les-Maures	3.43
Paris 9e Arrondissement	3.43
Paris 6e Arrondissement	3.38
Saint-Cyr-sur-Mer	3.24
Chantilly	3.13
Pornichet	3.06
Saint-Mandé	3.06
Paris 10e Arrondissement	3.04
Menton	2.94
Saint-Hilaire-de-Riez	2.87
Vincennes	2.81



Fin !