Analyse des ventes d’une librairie en ligne

Plan

1- Introduction

1.1 Objectifs et contexte

1.2 Données et méthodologie

1.3 Vue d'ensemble

2- Comprendre les ventes

2.1 Comment le chiffre d'affaire évolue-il dans le temps?

2.2 Evolution de chiffre d'affaires par catégorie

2.3 Comment le nombre des transactions évolue-t-il dans le temps?

2.4 Comment les ventes évoluent-elles ?

2.5 Evolution simultané des ventes, transactions et CA.

2.6 Evolution du nombre de clients

3- Les produits

3.1 Les produits tops et flop

3.2 Les produits qui ne se vendent jamais

4- Le poids des clients

4.1 Les ventes sont-elles concentrées sur quelques clients ?

5- Facteurs explicatifs des achats:

5.1 Genre et catégorie acheté

5.2 l'âge et le dépense totale

5.3 l'âge et la fréquence d'achat

5.4 l'âge et le panier moyen

5.5 Age et catégorie de livre

6- Conclusion

1.1 Objectifs et contexte

Quels facteurs expliquent les ventes dans cette librairie ?

- Evolution dans le temps:

Chiffre d'affaires, ventes, clients, paniers

- Les produits:

Catégories, prix

- Les clients:

Disparité, âge, genre, fréquence d'achat, dépenses

Données de ventes

- 687 534 transactions
- Sur deux ans :
- de 2022-03-01 à 2023-02-28

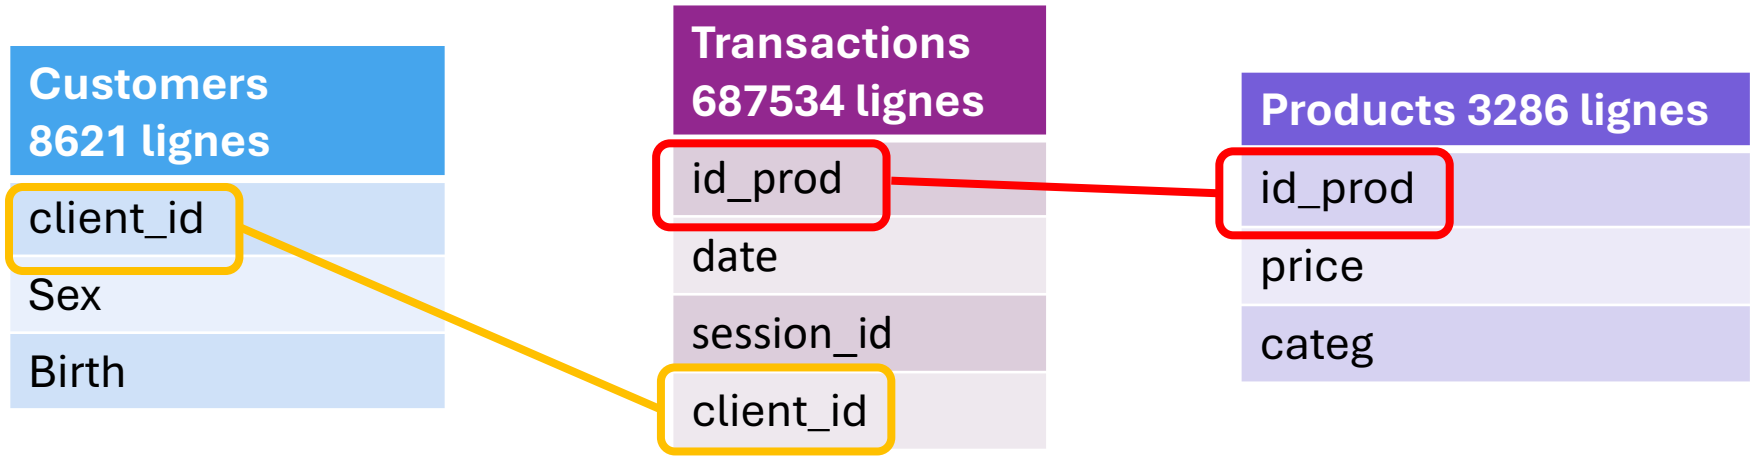
Catalogue :

- 3286 livres
- répartis en 3 catégories (0, 1,2)
- Prix moyen: 23 €

Clients:

- 8621 clients uniques

1.2 Données et méthodologie



Fusionner les 3 tables :

1- Table des ventes (une ligne par produits vendu)

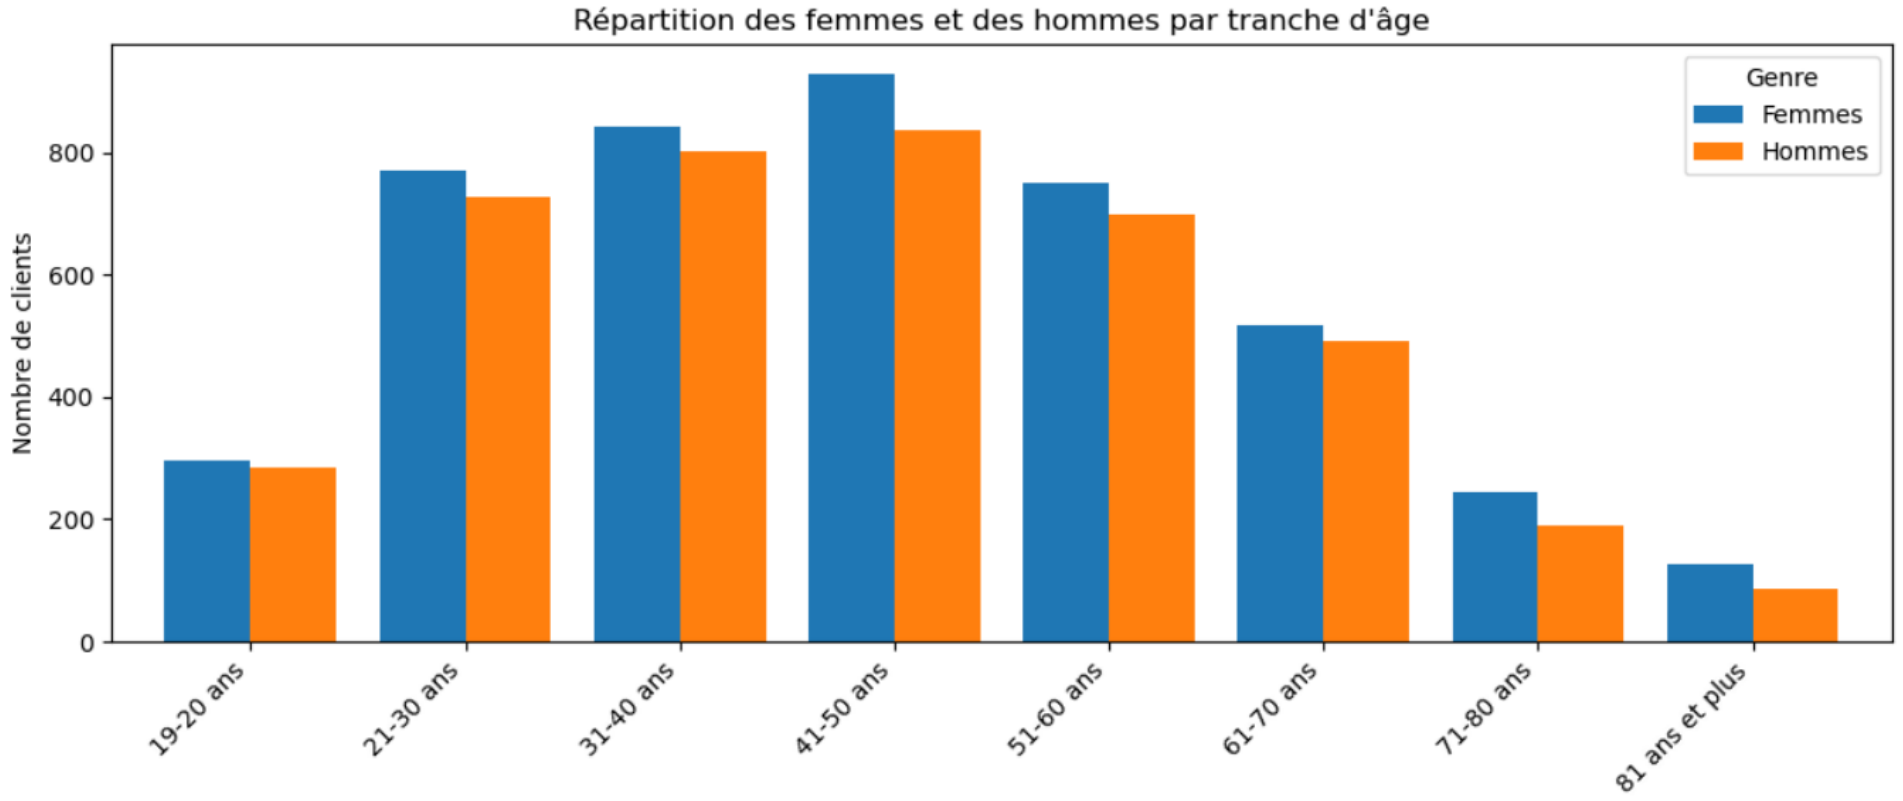
	id_prod	date	session_id	client_id	price	categ	sex	birth	age
0	0_1259	2021-03-01 00:01:07.843138	s_1	c_329	11.99	0	f	1967	56
1	0_1390	2021-03-01 00:02:26.047414	s_2	c_664	19.37	0	m	1960	63

2- Table des clients – consolidé – une ligne par client (qui ont déjà acheté)

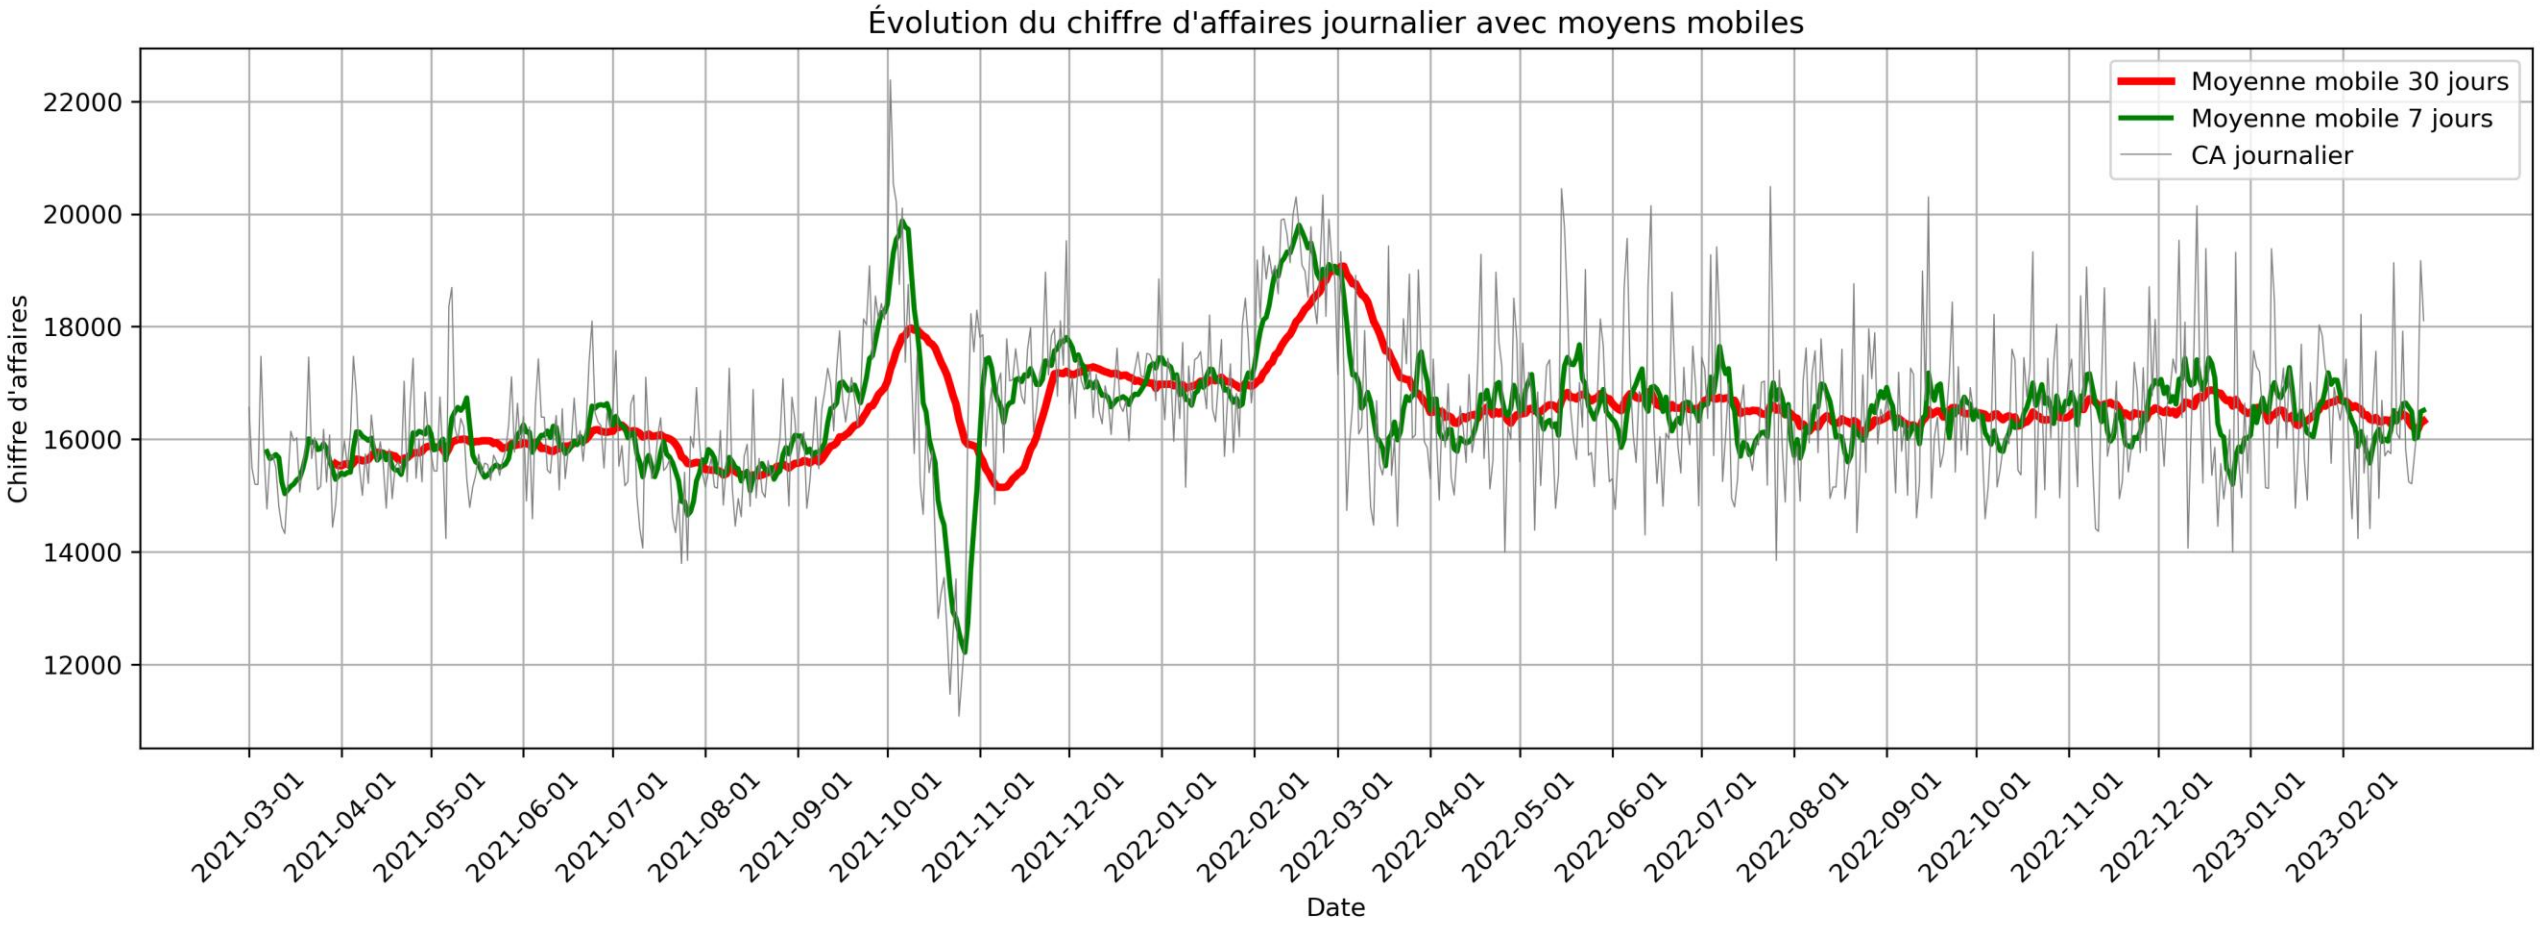
	client_id	sex	birth	age	tranche_age10	tranche_age20	montant_total	nombre_achats	nombre_produits	panier_moyen
0	c_1	m	1955	68	61-70 ans	51-70 ans	629.02	34	43	18.50

1.3 Vue d'ensemble

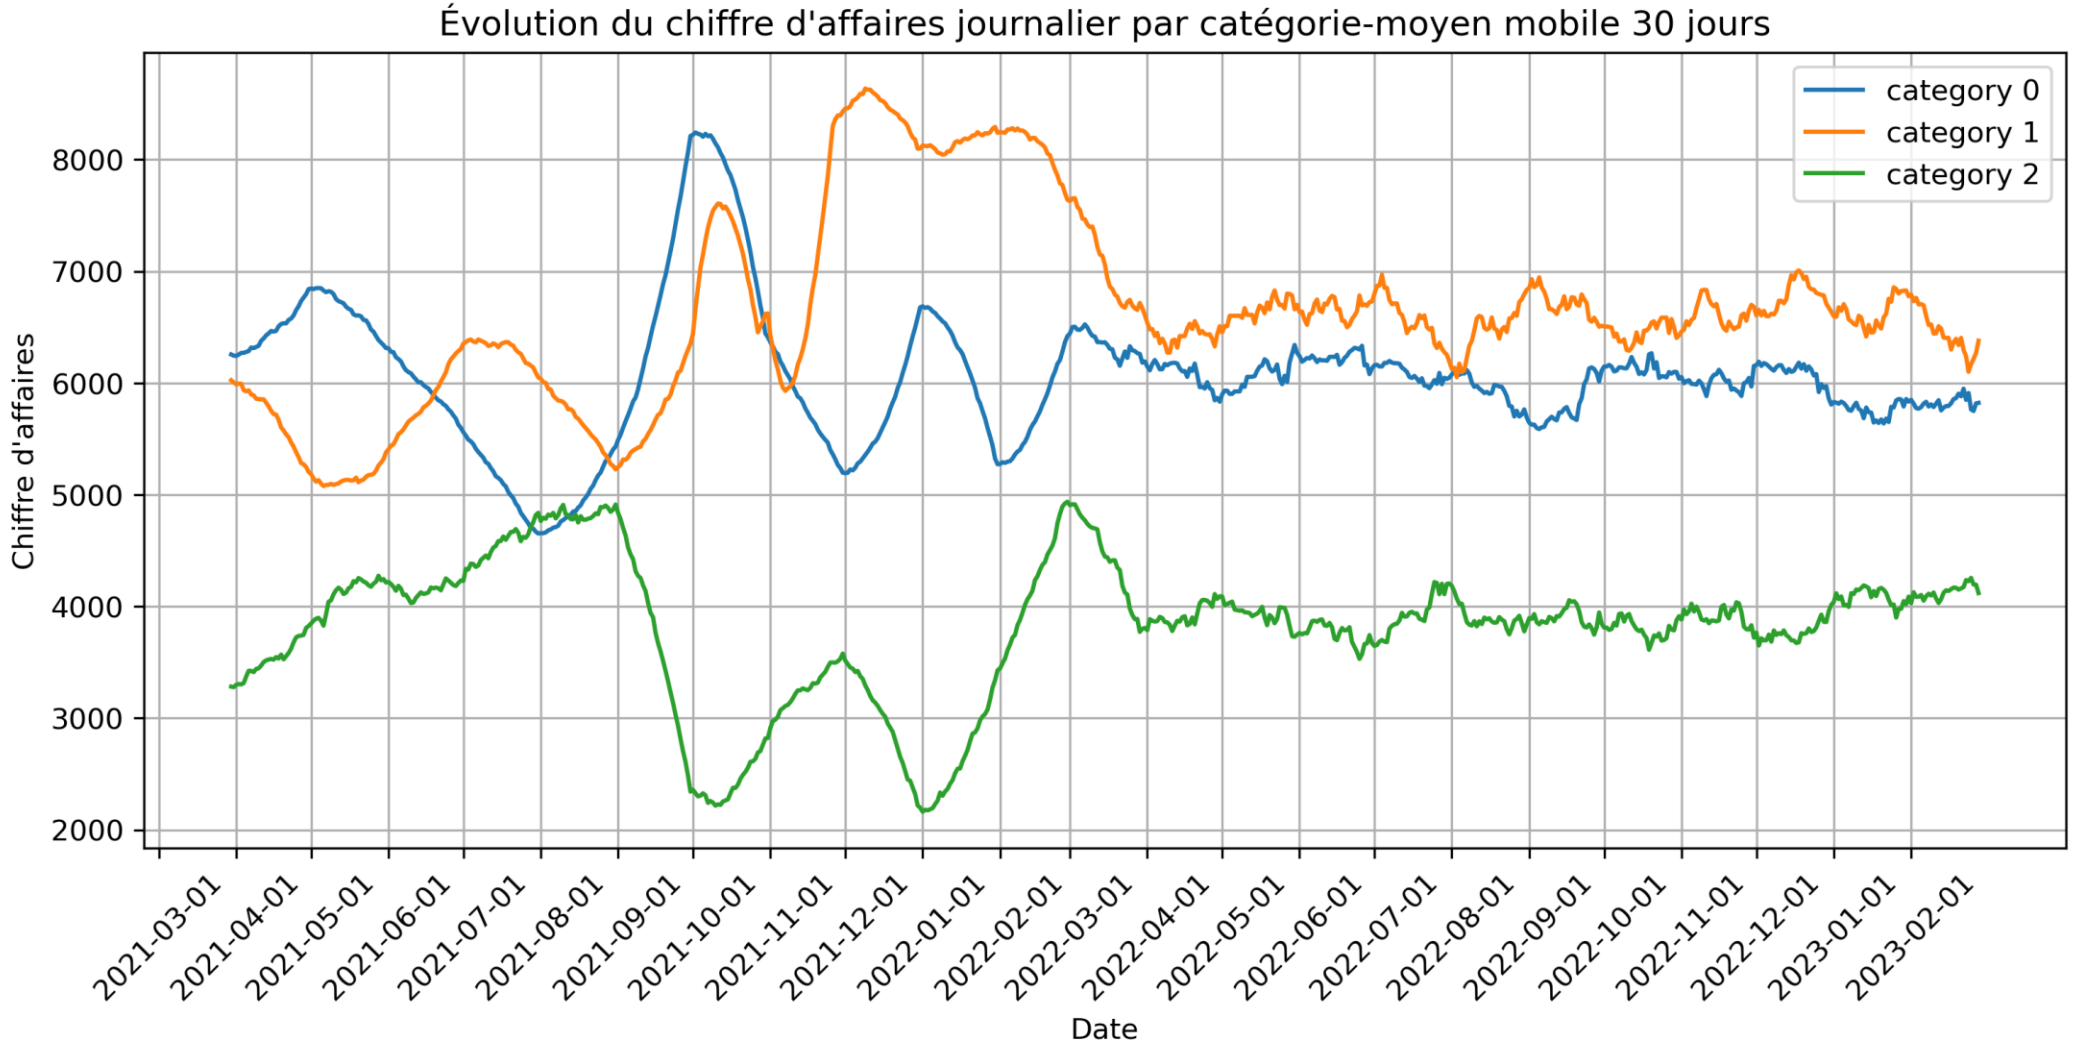
categ	nombre_produits	prix_moyen	quantite_moyenne	quantite_totale	ca_moyen	ca_total
0	**2 292**	11,71 €	181,26	**415 459**	1 928,33 €	4 419 730,97 €
1	737	25,50 €	**319,66**	235 592	6 550,42 €	**4 827 657,11 €**
2	236	**107,64 €**	154,59	36 483	**11 780,83 €**	2 780 275,02 €



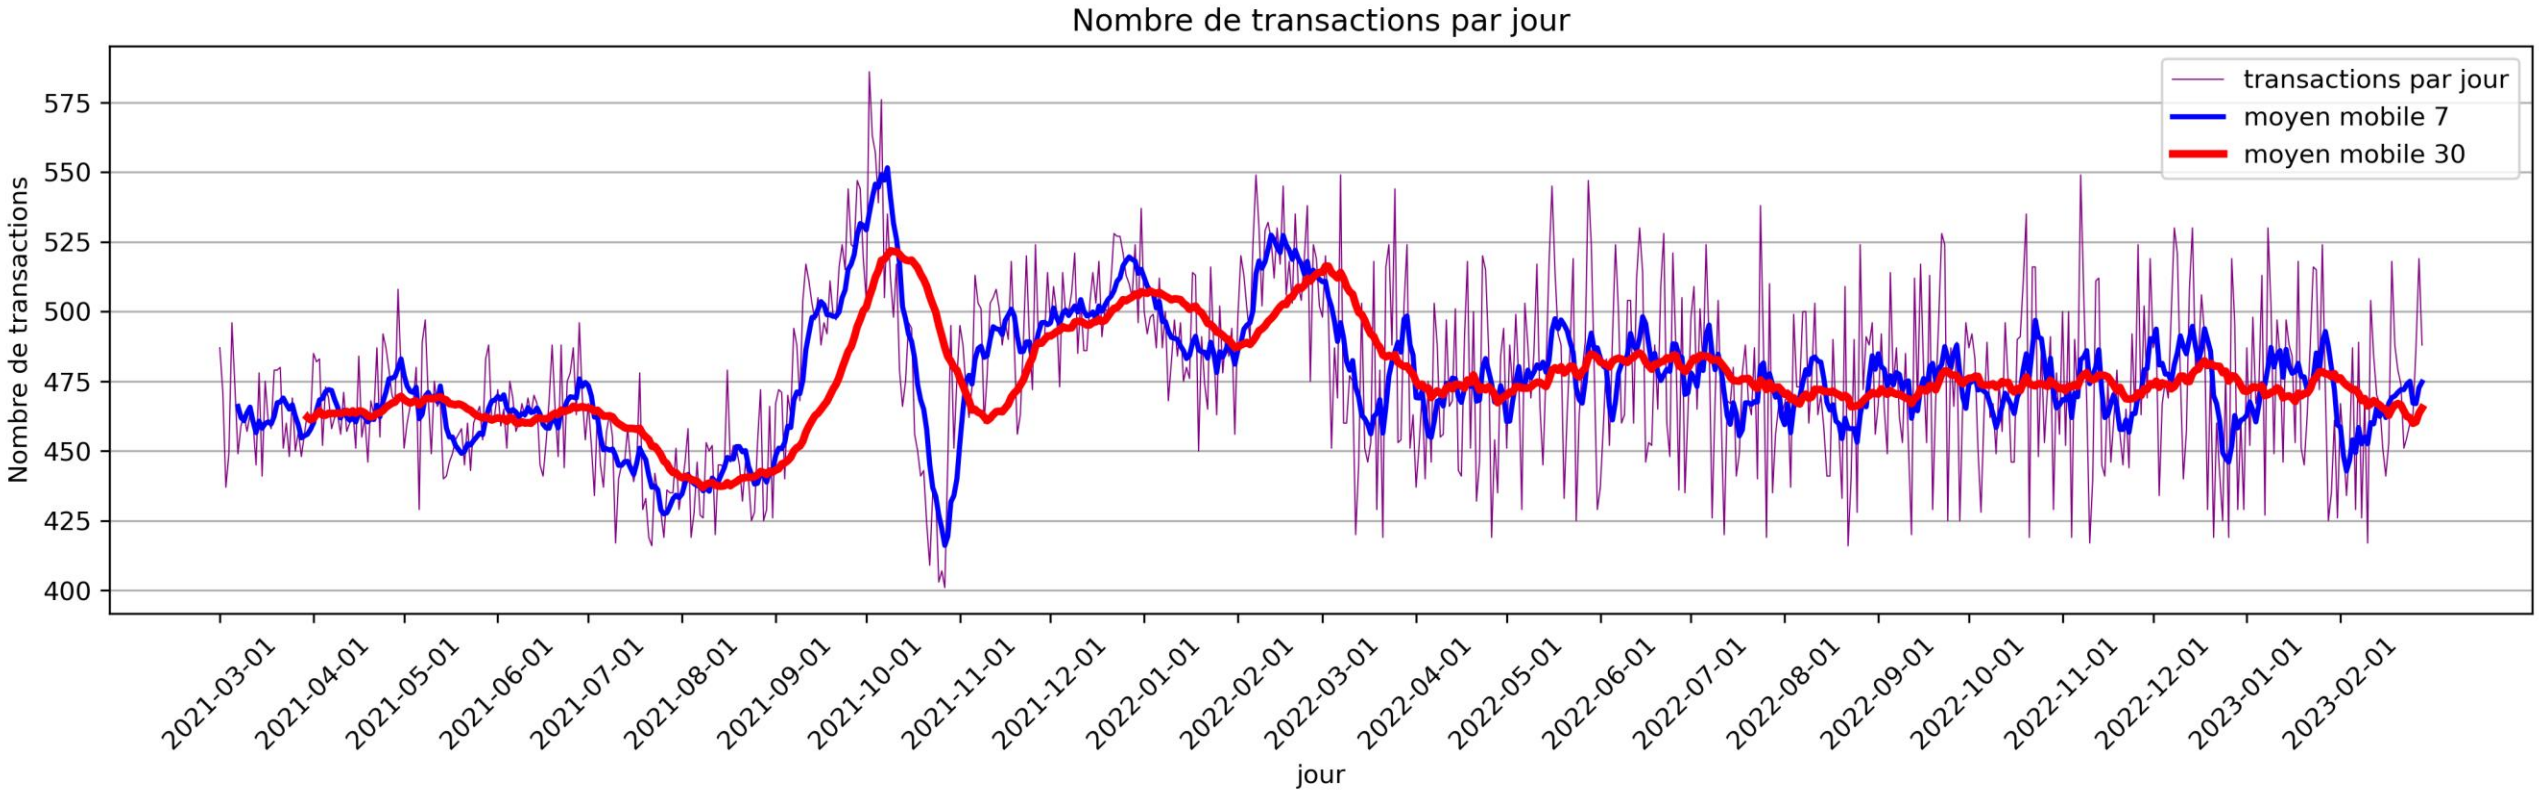
2.1 Comment le chiffre d'affaire évolue-il dans le temps?



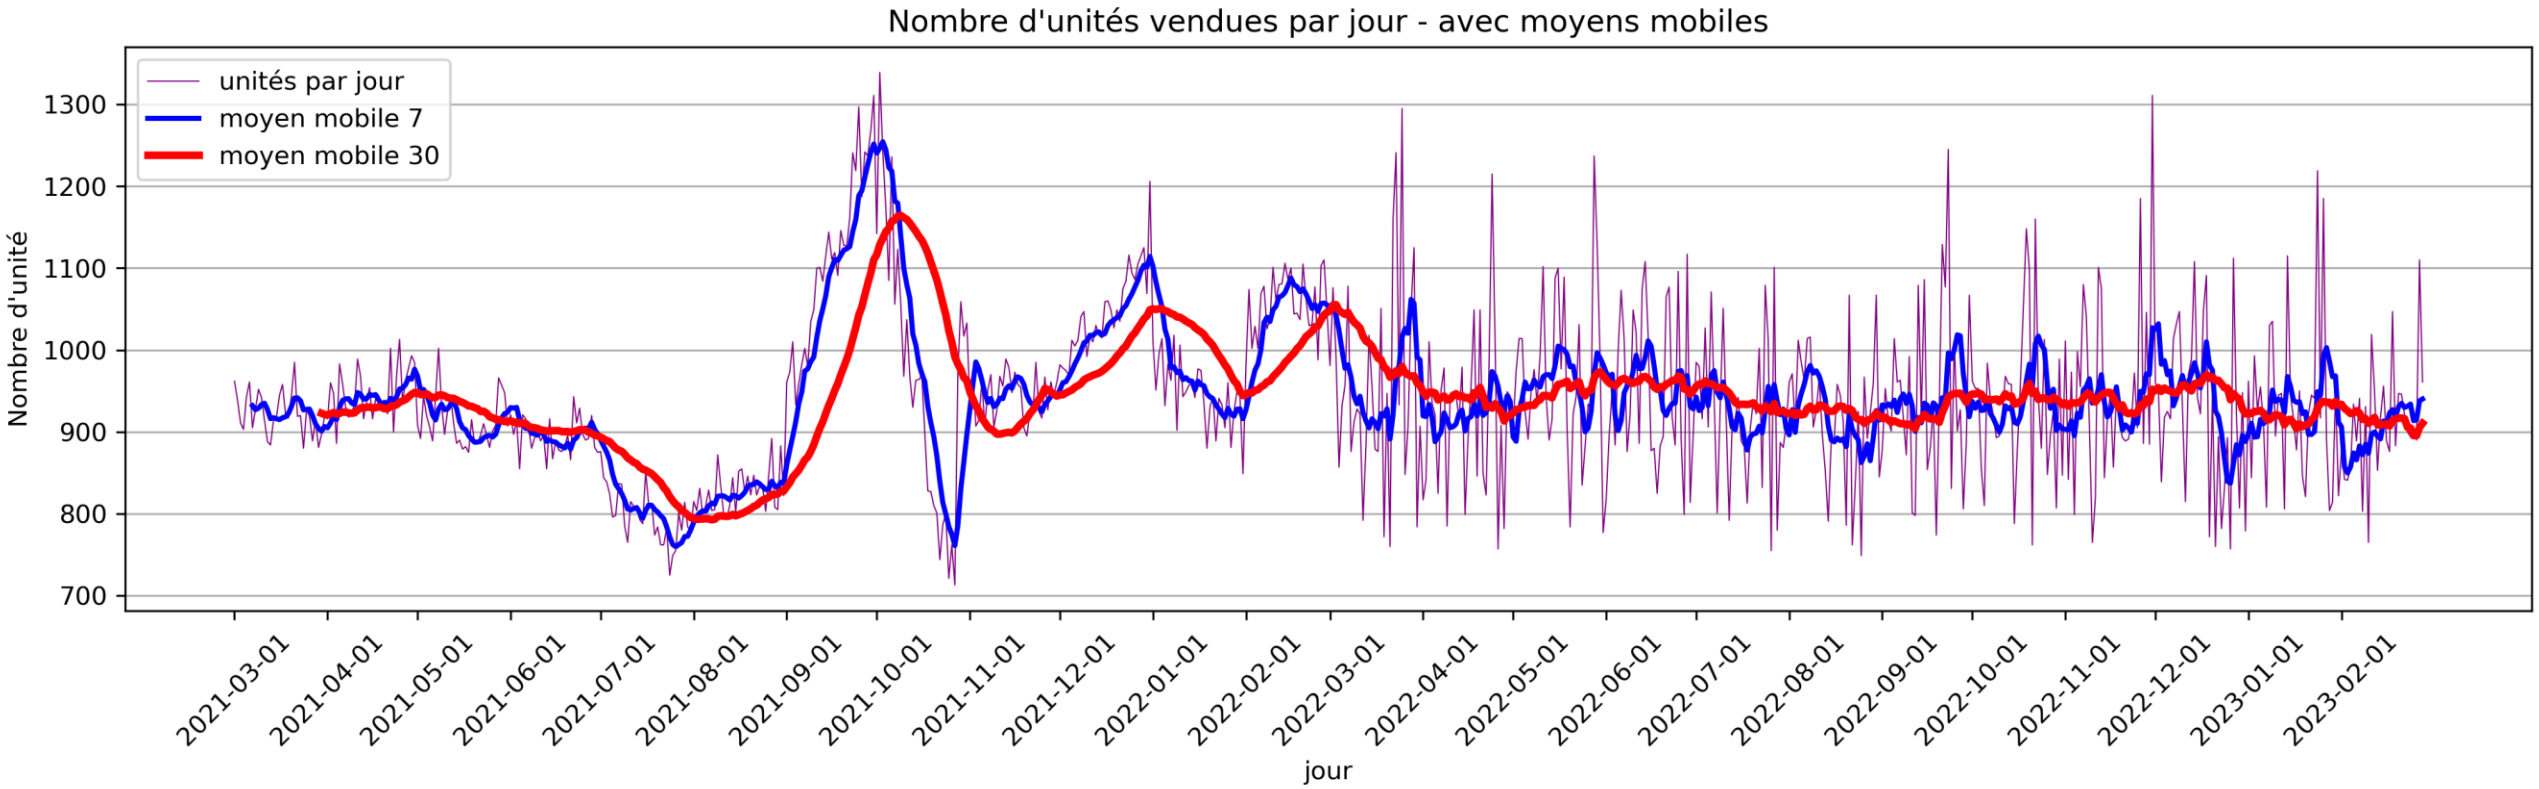
2.2 Evolution de chiffre d’affaires par catégorie



2.3 Comment le nombre des transactions évolue-t-il dans le temps?

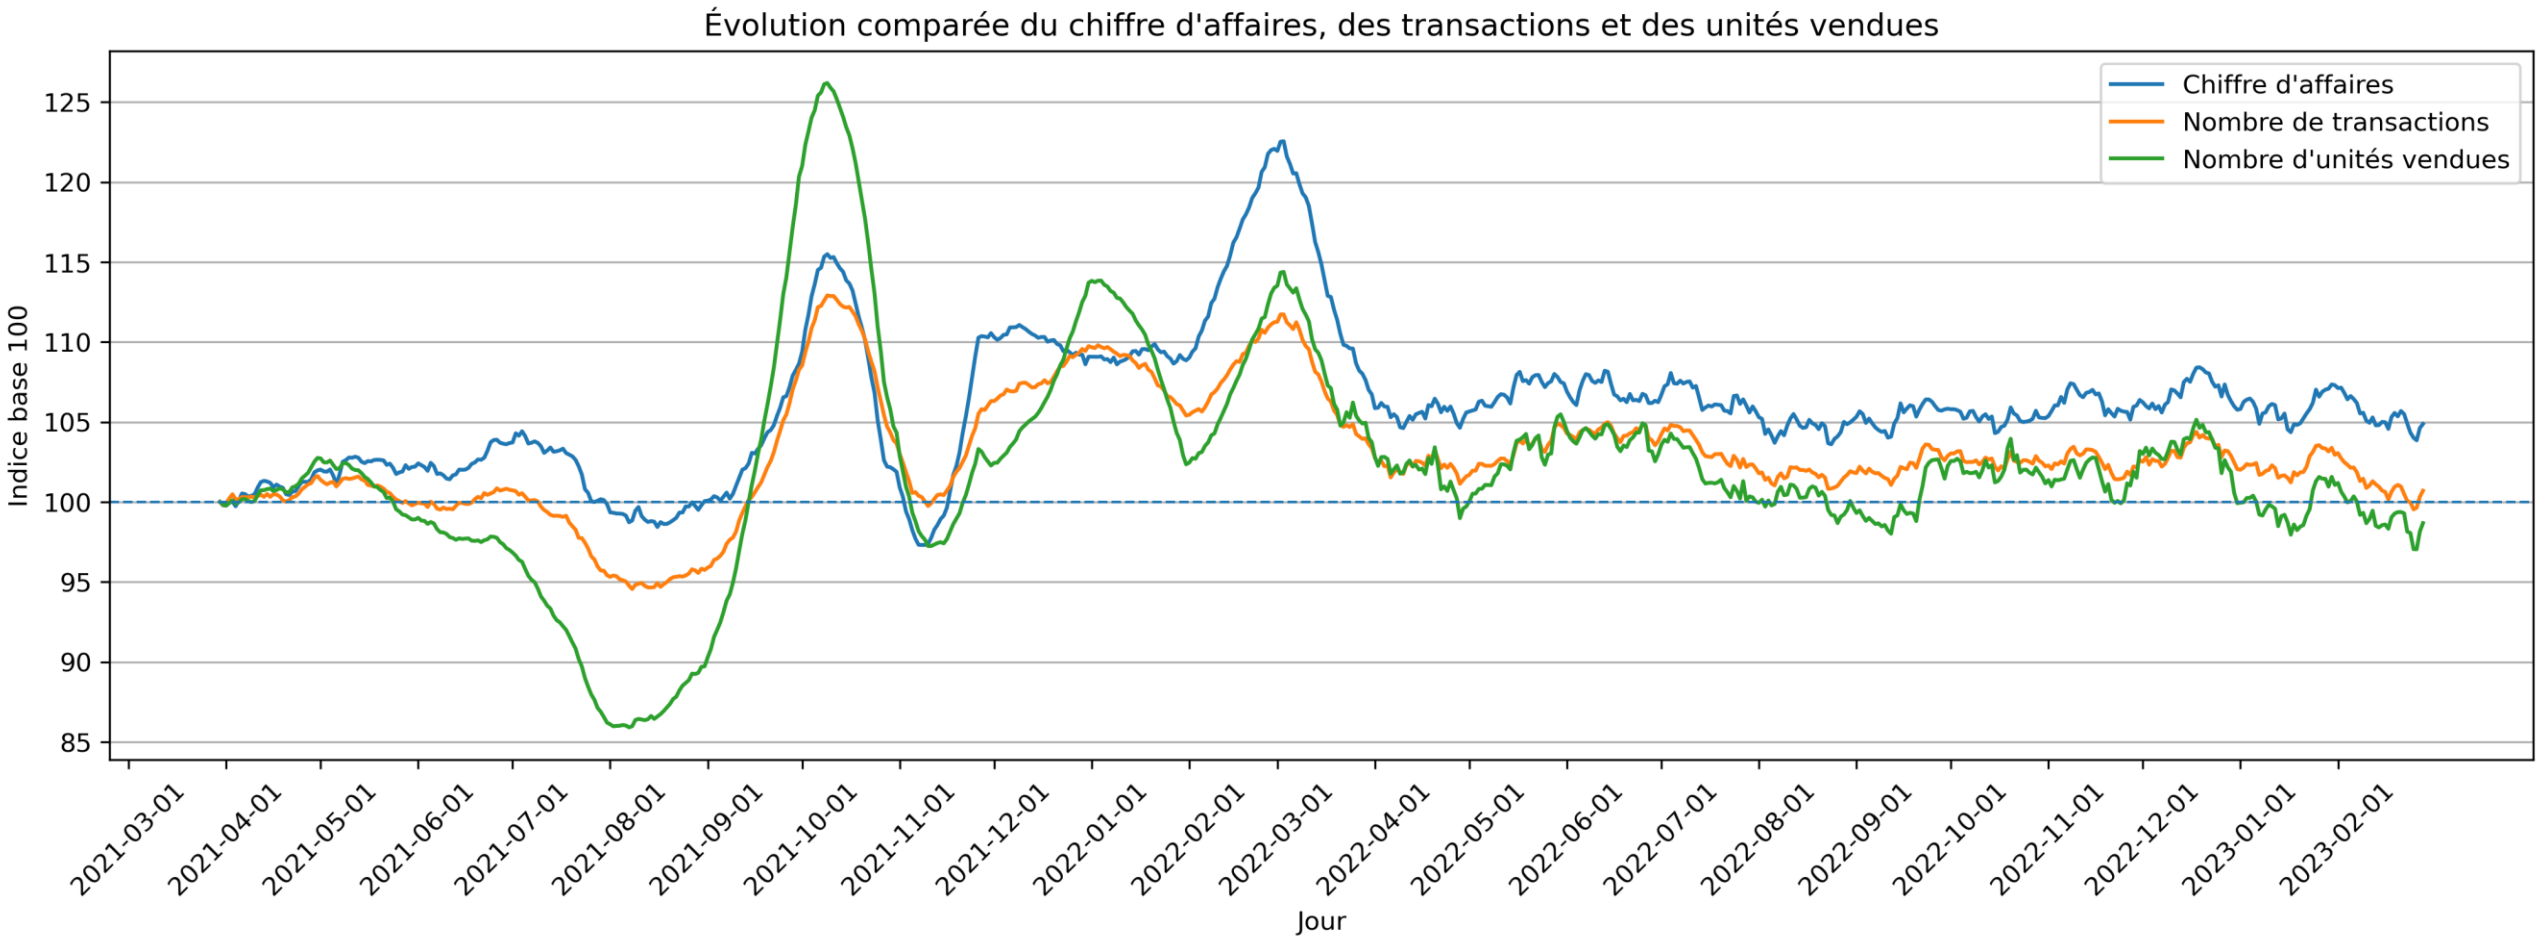


2.4 Comment les ventes évoluent-elles ?

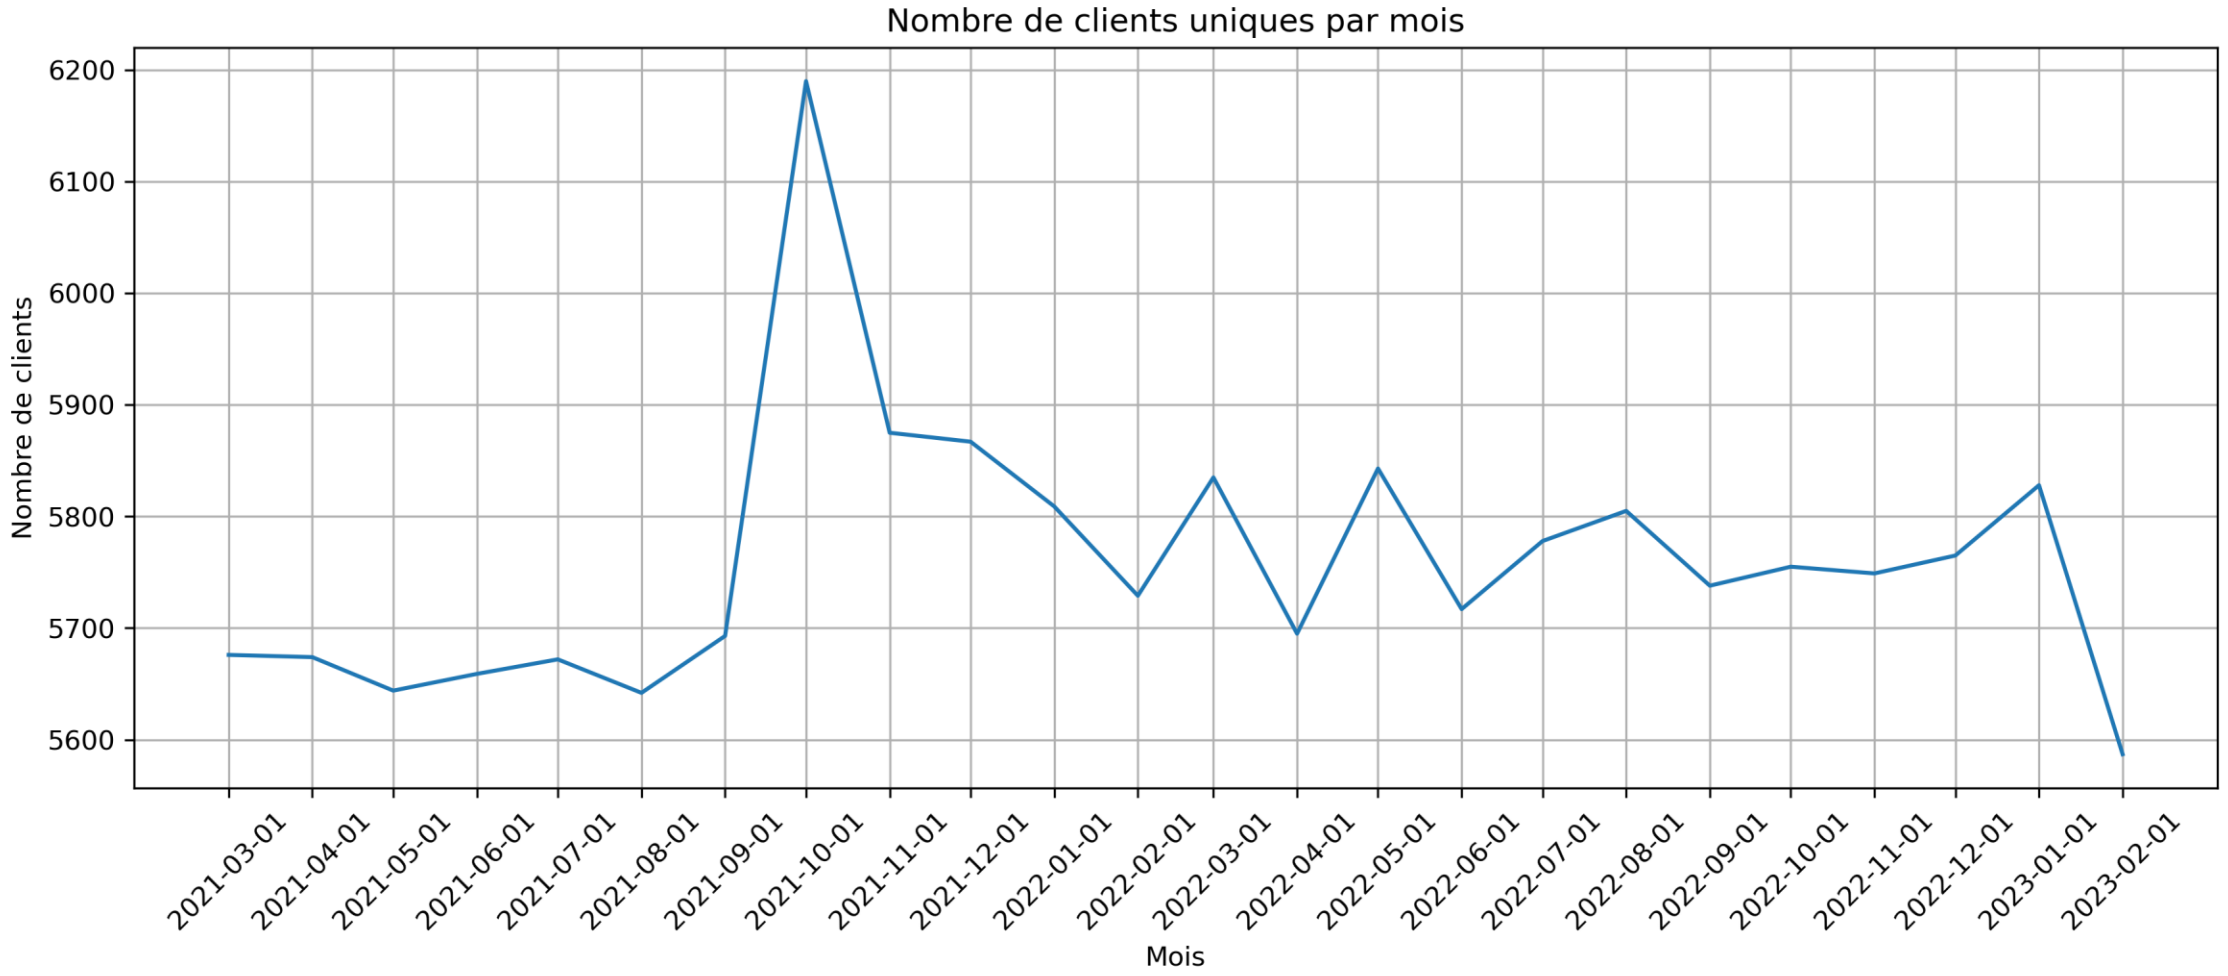


2.5 Evolution simultané des ventes, transactions et CA.

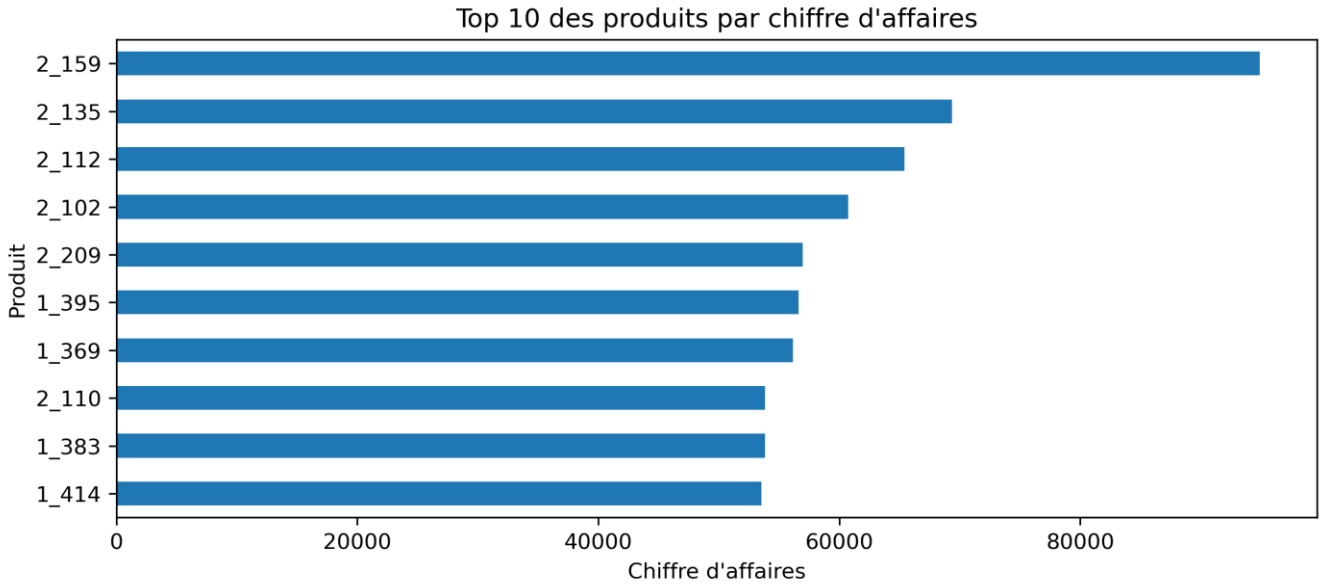
Evolution des moyens mobiles sur 30 jour
Indice calculé sur base 100, le premier jour comme référence



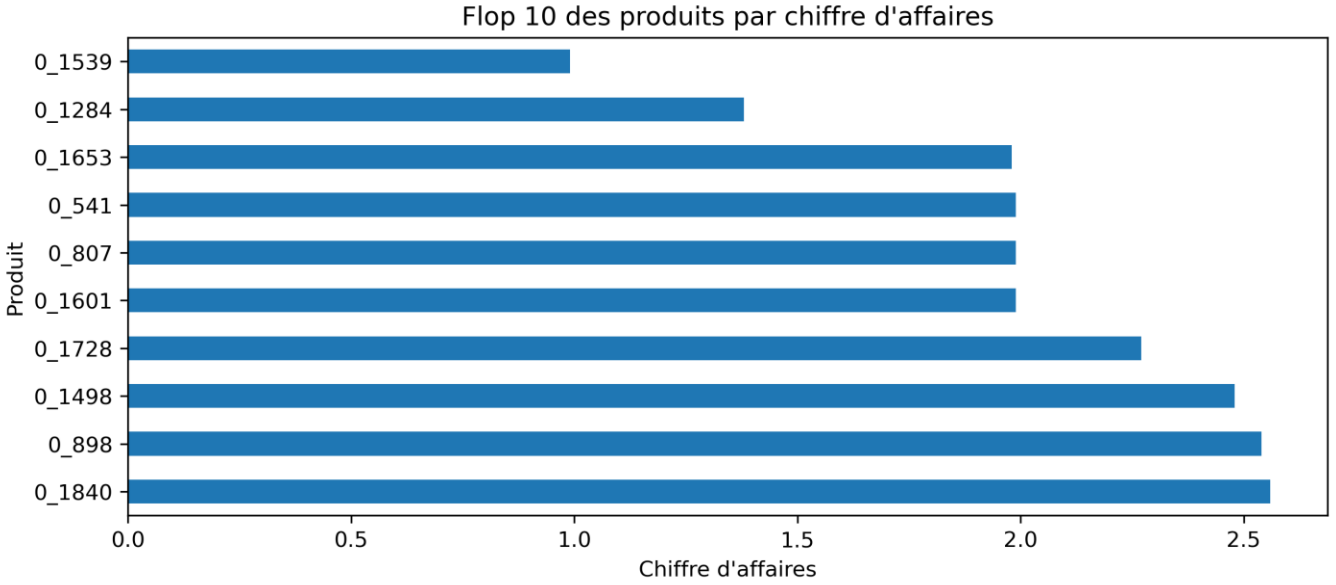
2.6 Evolution du nombre de clients



3.1 Les produits tops et flops



Les produits les plus rentables sont dans la catégorie 2 (niche)



Les produits les moins rentables sont dans la catégorie 0 (parmi ceux qui sont vendus au moins une fois)

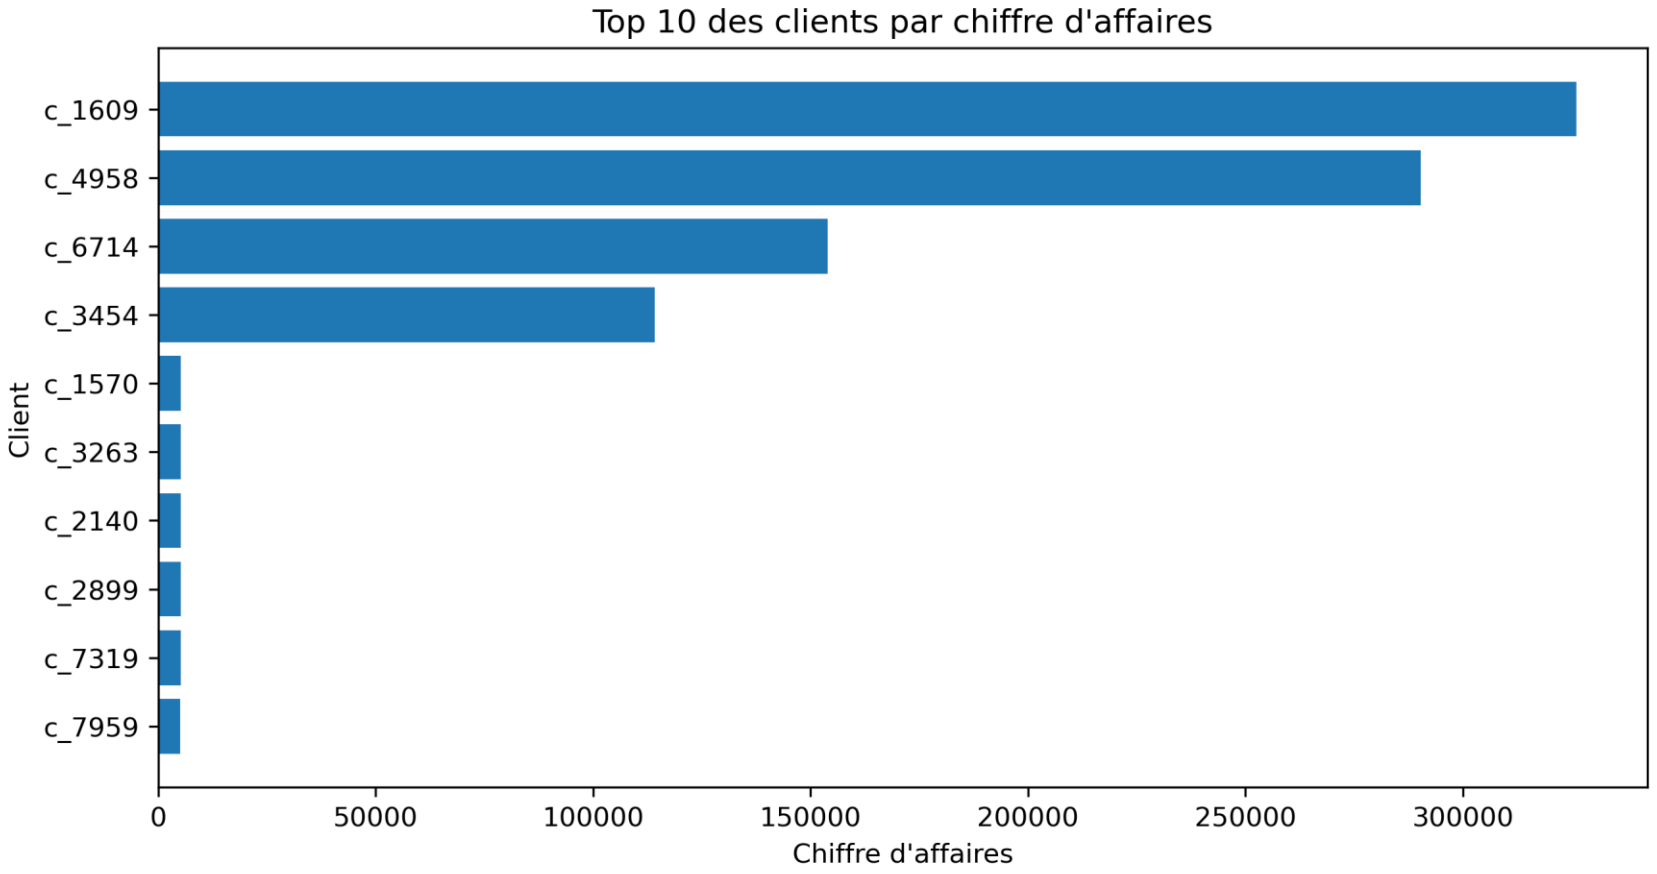
3.2 Les produits qui ne se vendent jamais

21 des produits sur le catalogue n'ont pas été vendus

id_prod	price	categ
0_1016	35,06	0
0_1780	1,67	0
0_1062	20,08	0
0_1119	2,99	0
0_1014	1,15	0
0_1318	20,92	0
0_1800	22,05	0
0_1645	2,99	0
0_322	2,99	0
0_1620	0,8	0
0_1025	24,99	0
0_310	1,94	0
0_1624	24,5	0
0_299	22,99	0
0_510	23,66	0
0_2308	20,28	0
1_0	31,82	1
1_394	39,73	1
2_87	220,99	2
2_72	141,32	2
2_86	132,36	2

Trop chers?

4.1 Les ventes sont-elles concentrées sur quelques clients ?



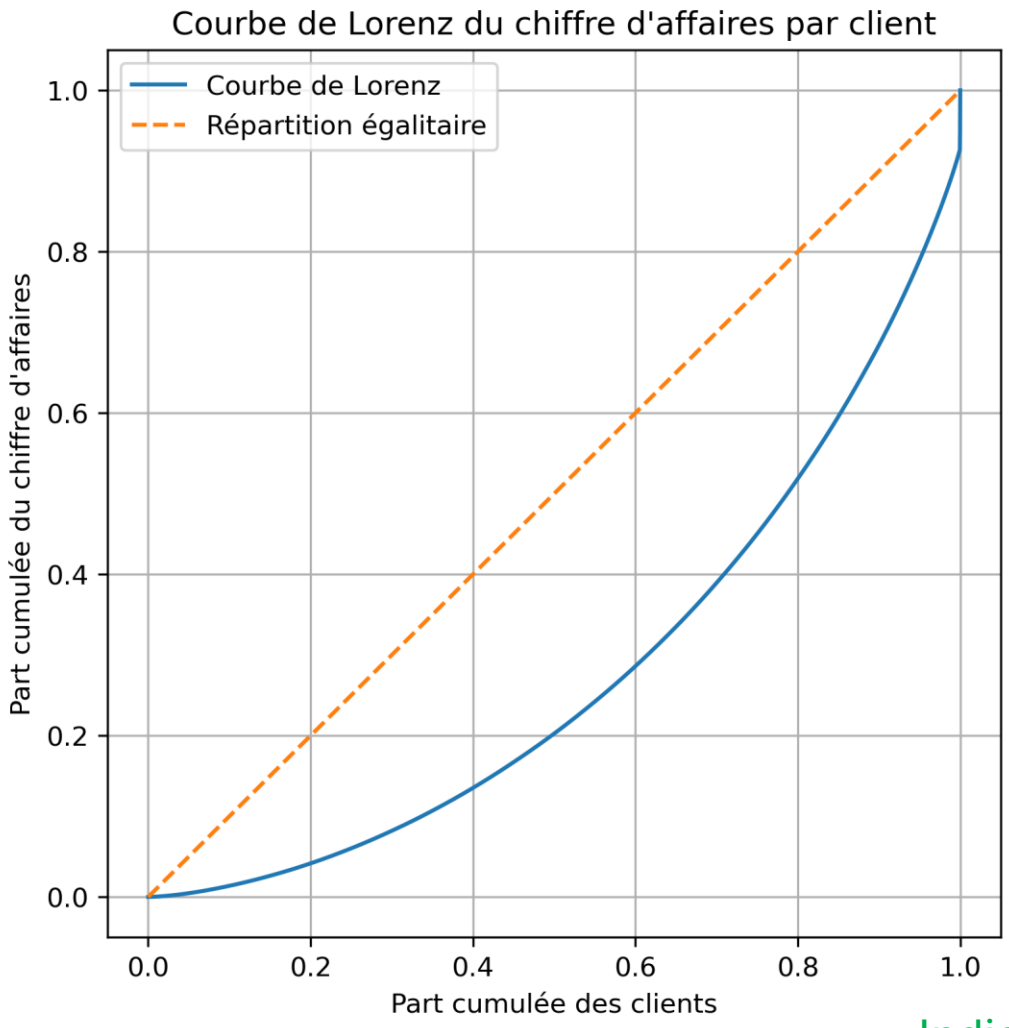
4 clients parmi 8621 sont B to B
Ils représentent:

0,05% des clients
7,35% de chiffre d'affaires
6.81 % des produits achetés

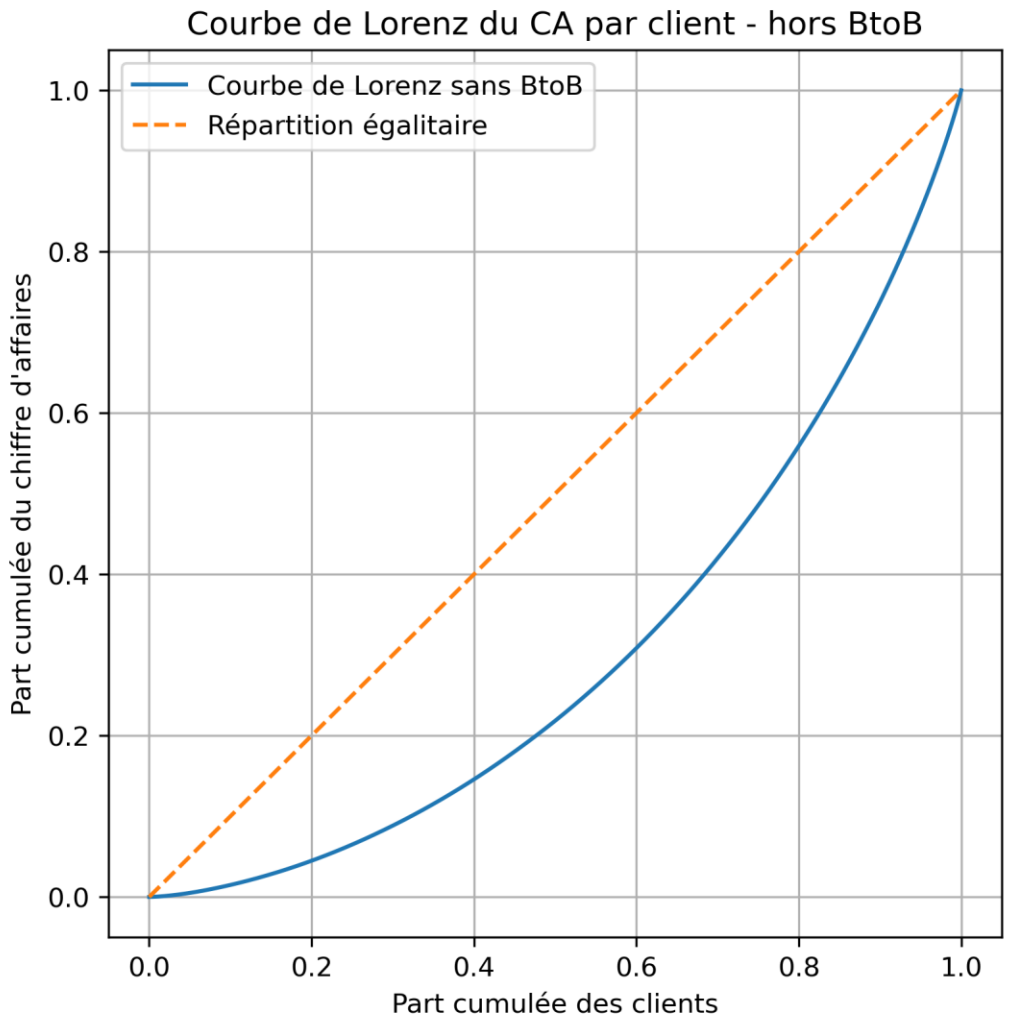
Calcul de courbe de lorenz et coefficient de Gini pour repérer les inégalités de répartition de chiffre d'affaires entre clients

Nous sommes sûr d'avoir trouvé les 4 clients B to B

4.1 Les ventes sont-elles concentrées sur quelques clients ?



Gini = 0,442



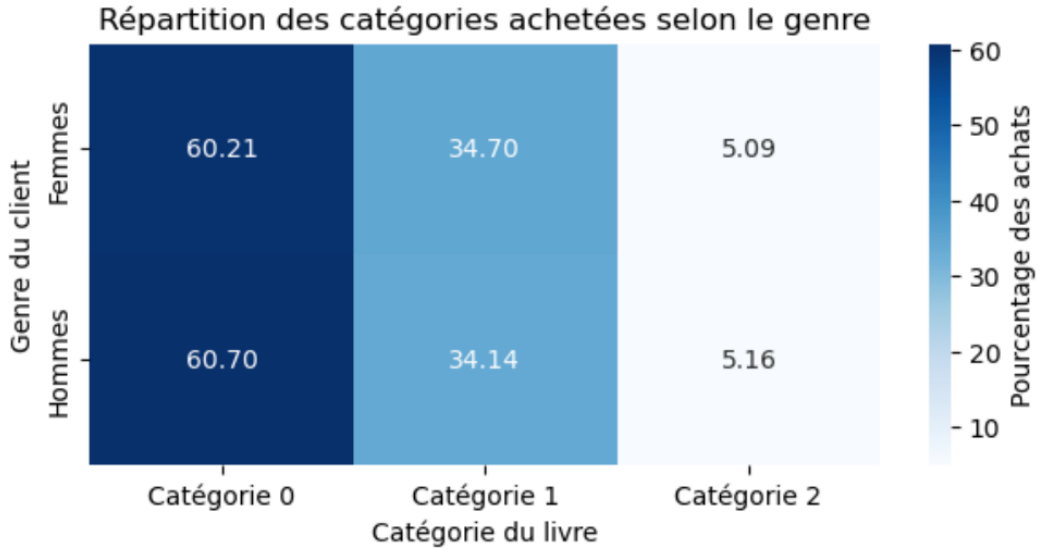
Gini = 0,398

Indice de gini:
Si proche de 0: répartition égalitaire
Si proche de 1: fortement concentré

5.1 Genre et catégorie acheté

Effectifs

	Catégorie 0	Catégorie 1	Catégorie 2
Femmes	200793	115721	16980
Hommes	186488	104884	15868



H0 : le genre et la catégorie de livres achetée sont indépendants.
H1 : il existe une association entre le genre et la catégorie achetée.

2 variables qualitatives : Test de khi^2

Statistique du khi^2 : 22.669
Degrés de liberté : 2
P-value : 1.195593e-05

P-value < 0,05 => H0 est rejeté
il y a une association statistiquement significative entre le genre et la catégorie acheté

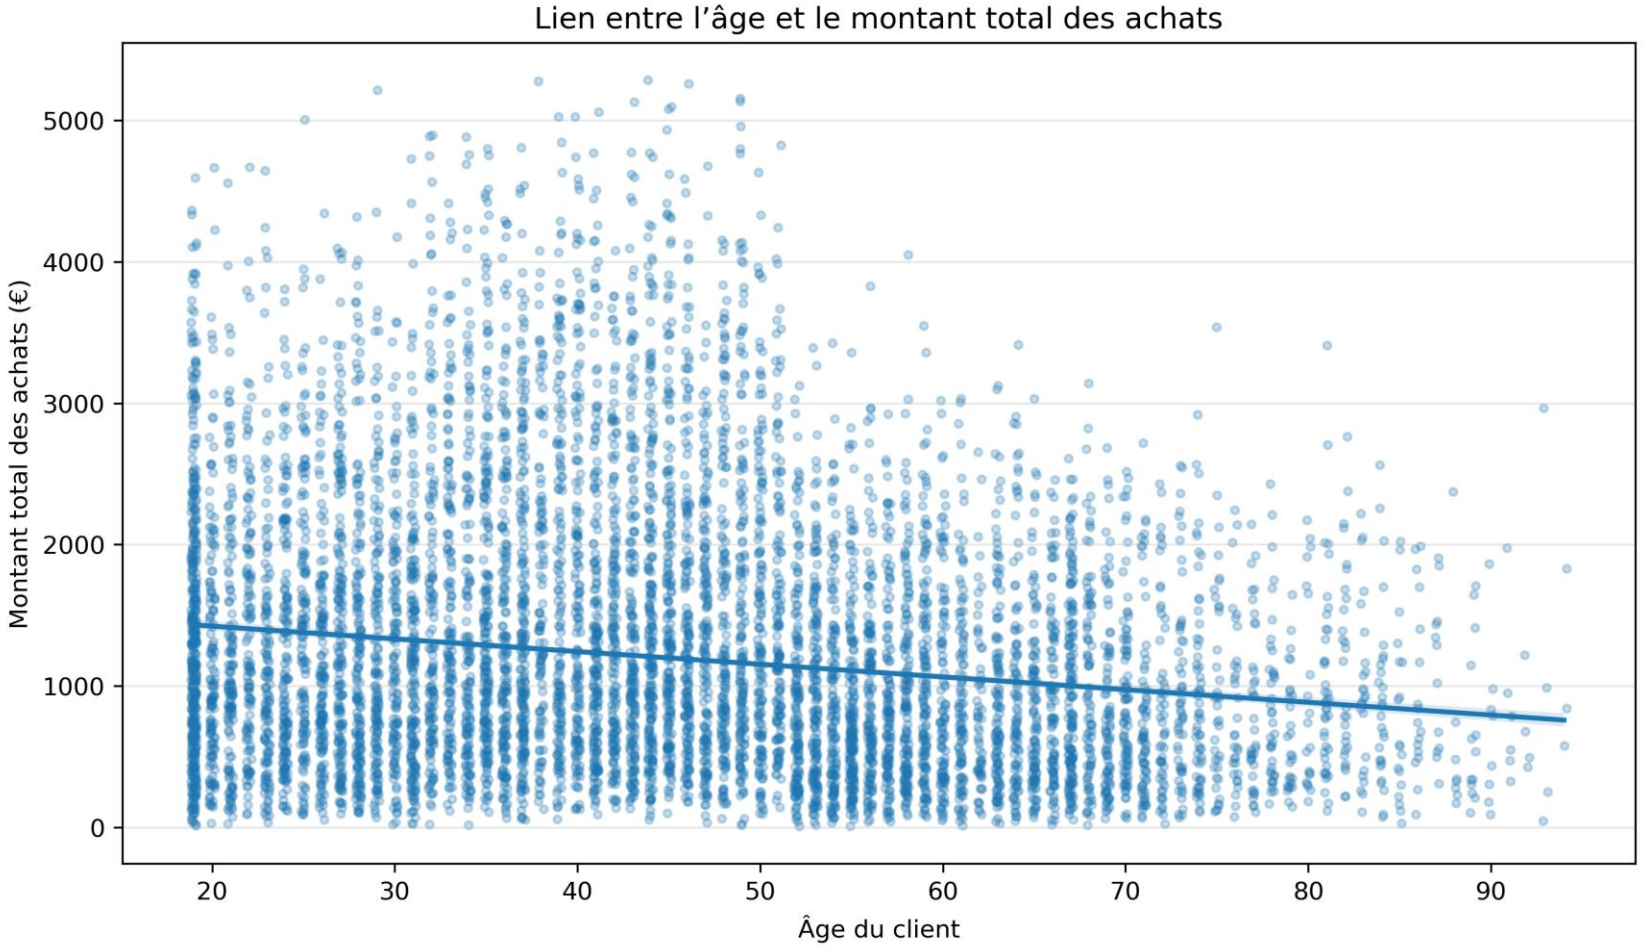
Complément: V de Cramer = 0.0059

Proche de 0 => intensité d'association faible, négligeable

Il existe une association statistiquement significative entre le genre et la catégorie mais son intensité est très faible

5.2 L'âge et le dépense totale

- **H0 :** il n'existe pas de corrélation linéaire entre l'âge et le montant total des achats,
- **H1 :** il existe une corrélation linéaire entre l'âge et le montant total des achats,



Tests de correlation

Pearson :
r = -0.1876
p-value = 6.663512e-69

Spearman :

rho = -0.1845
p-value = 1.021291e-66

Les deux rejette H0.
Il existe une corrélation négative et significative, mais très faible

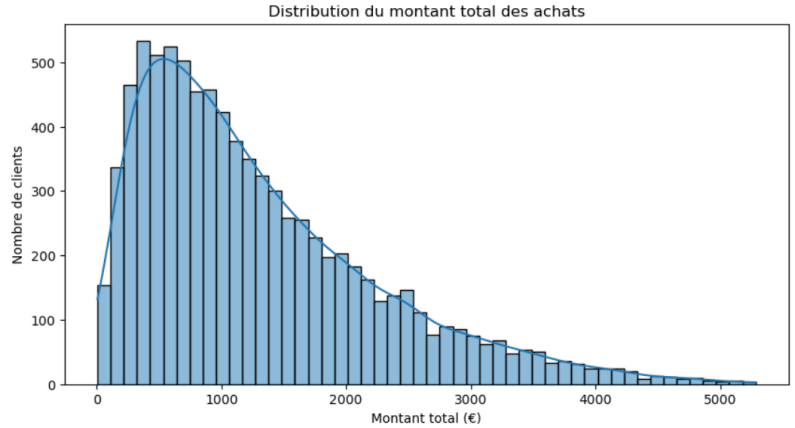
Pourtant

5.2 L'âge et le dépense totale

Conditions pour utiliser les tests

Pearson:
- 2 variables quantitatives
- Indépendantes
- Corrélation linéaire
- Normalement distribuée

Non, car les variables ne sont pas normalement distribué

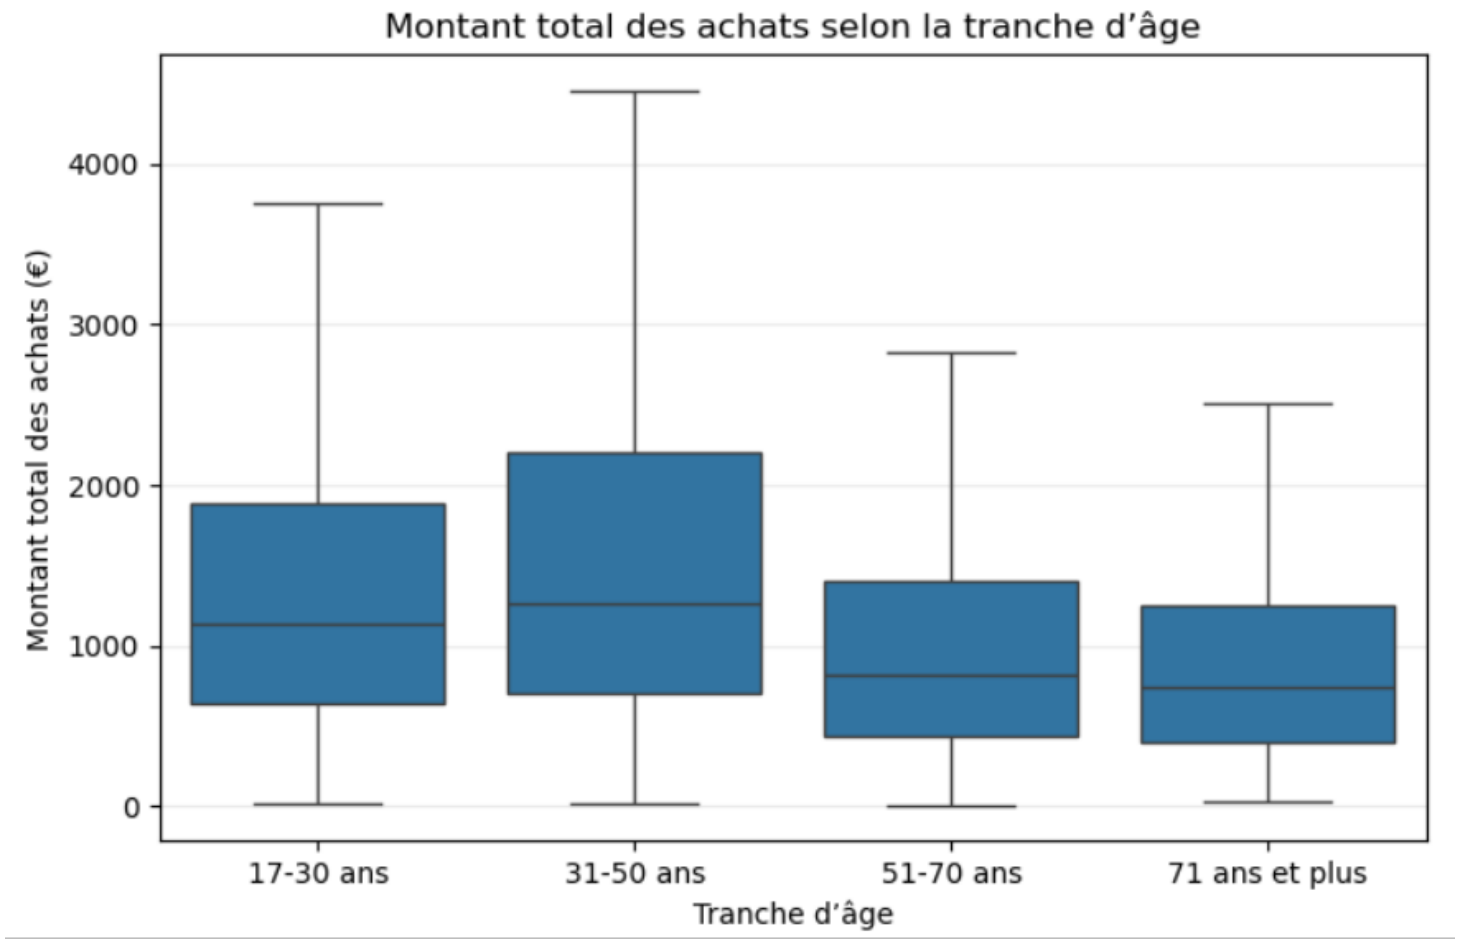


Spearman:
- 2 variables quantitatives
- Indépendantes
- Corrélation pas nécessairement linéaire mais monotone
- Distribution normale n'est pas nécessaire

Non, car la relation n'est pas monotone

Autre solution : diviser l'âge en catégories de 20 ou 10 ans

5.2 L'âge et le dépense totale



tranche_age20	effectif	moyenne	mediane	q1	q3	ecart_interquartile
17-30 ans	2080	1351.90	1139.40	638.31	1884.27	1245.97
31-50 ans	3410	1556.50	1260.53	700.67	2203.62	1502.95
51-70 ans	2457	993.45	818.22	429.62	1397.34	967.72
71 ans et plus	649	898.04	743.95	394.64	1253.44	858.80

Visuellement, il existe une association entre l'âge et montant totale et cette association ne semble pas monotone

5.2 L'âge et le dépense totale

Une variable catégorielle
Une variable quantitative qui n'est pas normalement distribuée
Observation indépendantes (une ligne par client)

→ Test de **Kruskal-Wallis**

H0 : la distribution du montant total des achats est identique dans toutes les tranches d'âge.
H1 : au moins une tranche d'âge présente une distribution différente du montant total.

Statistique H : 556.4475
P-value : 2.782252e-120

→ Rejet de H0 : le montant total diffère significativement selon les tranches d'âge.

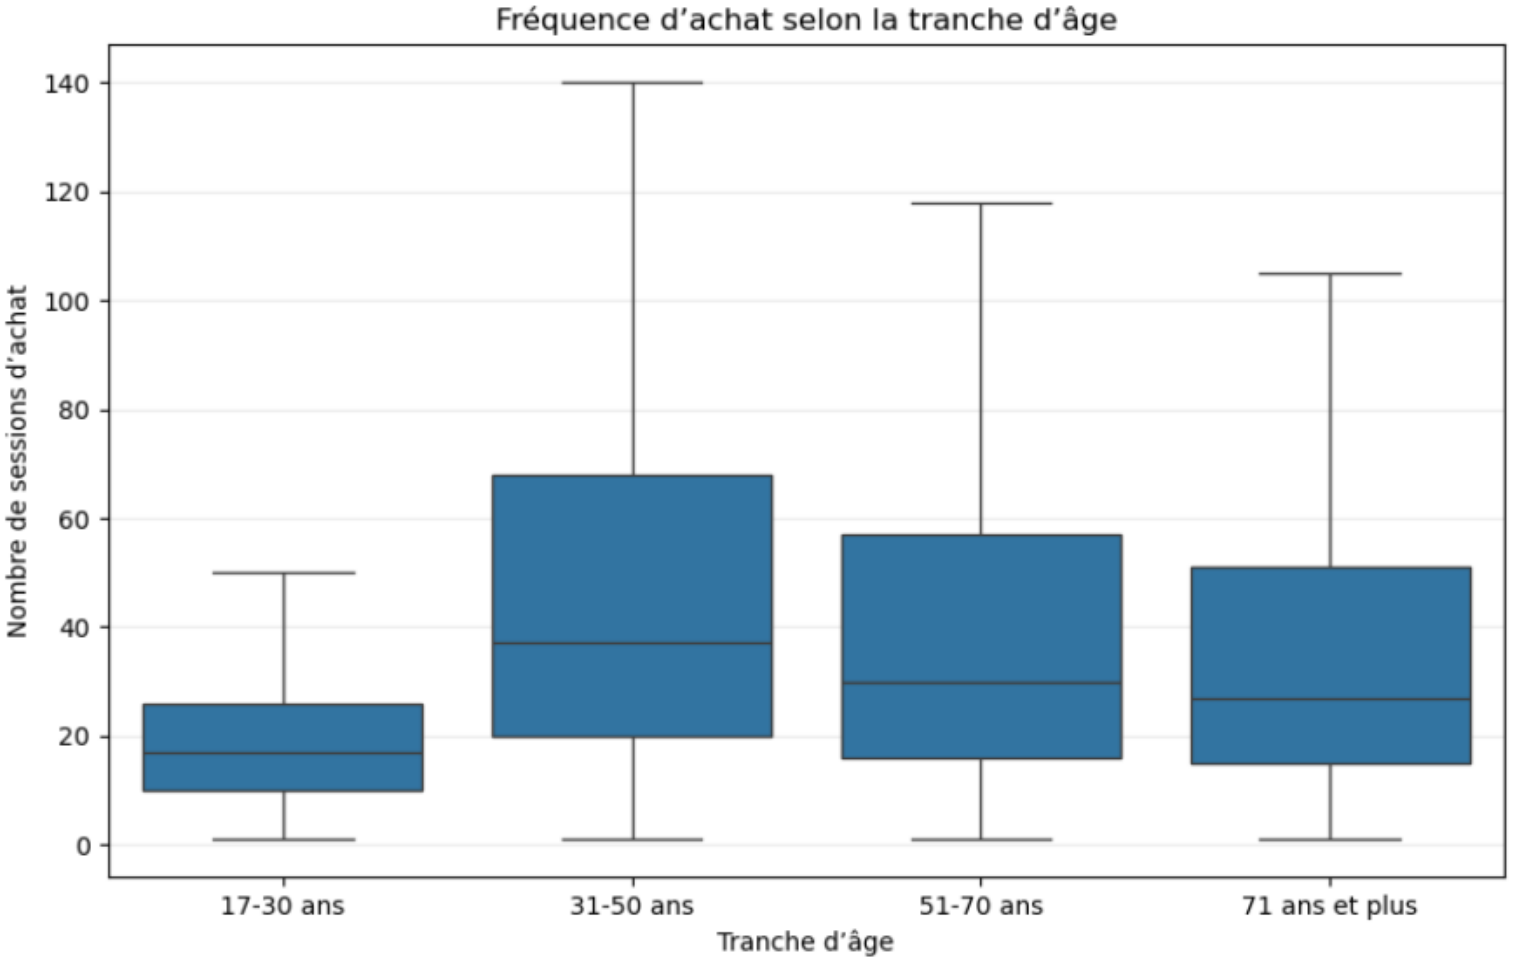
Epsilon carré : 0.0644

→ Association d'intensité modérée

<u>Taille de l'effet: calcul de epsilon carré</u>
autour de 0,01 : effet faible
autour de 0,06 : effet modéré
autour de 0,14 : effet important.

5.3 L'âge et la fréquence d'achat

La fréquence d'achat est le nombre total des sessions d'achat, ou le nombre totale des paniers



5.3 L'âge et la fréquence d'achat

tranche_age20	effectif	moyenne	mediane	q1	q3	ecart_interquartile
17-30 ans	2080	19.12	17.0	10.0	26.0	16.0
31-50 ans	3410	47.41	37.0	20.0	68.0	48.0
51-70 ans	2457	39.50	30.0	16.0	57.0	41.0
71 ans et plus	649	36.91	27.0	15.0	51.0	36.0

H0 : la distribution de la fréquence d'achat est identique dans toutes les tranches d'âge.
H1 : la distribution de la fréquence d'achat diffère pour au moins une tranche d'âge.

Test de **Kruskal-Wallis:**

Statistique H : 1213.9139
P-value : 7.019920e-263

Rejet de H0 : la fréquence d'achat diffère significativement selon les tranches d'âge

Taille de l'effet:

Epsilon carré : 0.1409 =>

il y a une différence important entre la fréquence d'achat selon la tranche d'age

Taille de l'effet: calcul de epsilon carré
autour de 0,01 : effet faible
autour de 0,06 : effet modéré
autour de 0,14 : effet important.

5.3 L'âge et la fréquence d'achat

Nous savons que toutes les tranches n'ont pas la même fréquence d'achat mais nous ne savons pas encore lesquelles diffèrent des autres

Comparer les tranches 2 à 2 avec un test de mann withney

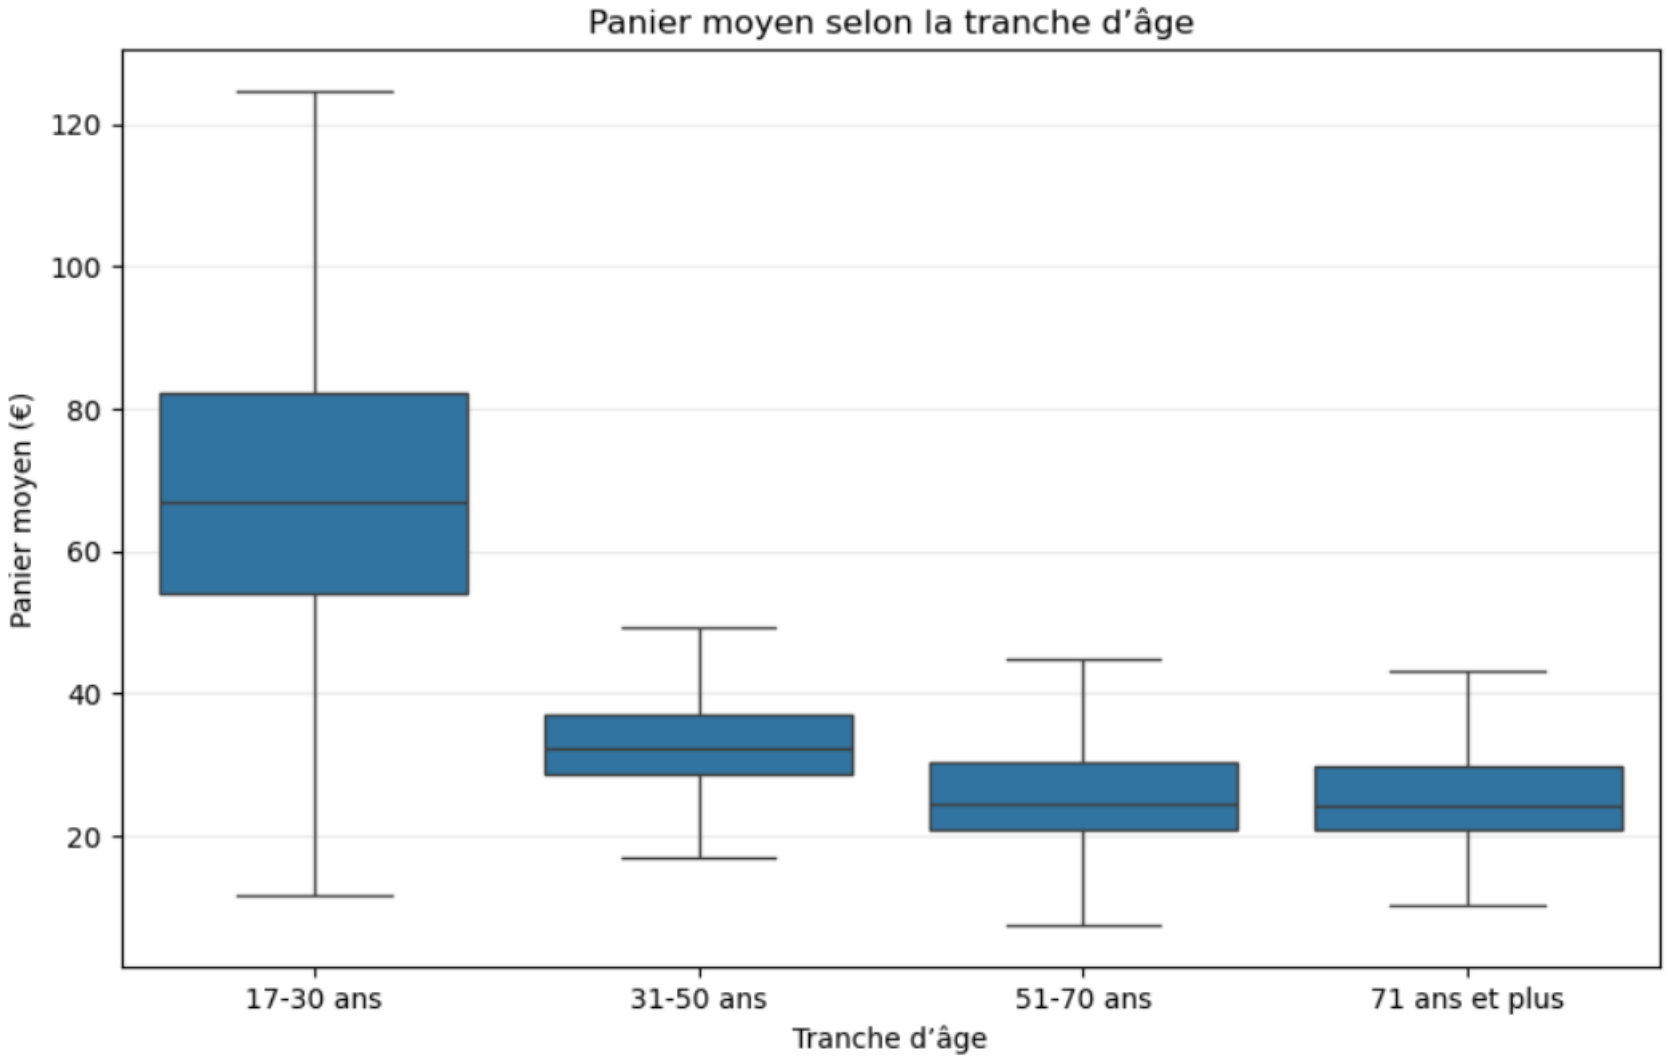
	comparaison	statistique_U	p_value_brute	p_value_corrigee	significatif
0	51-70 ans vs 31-50 ans	3634243.0	4.296490e-18	1.288947e-17	True
1	51-70 ans vs 71 ans et plus	838347.5	4.332852e-02	4.332852e-02	True
2	51-70 ans vs 17-30 ans	3638151.5	5.022334e-134	2.511167e-133	True
3	31-50 ans vs 71 ans et plus	1309191.5	1.298490e-13	2.596980e-13	True
4	31-50 ans vs 17-30 ans	5498374.5	2.318052e-257	1.390831e-256	True
5	71 ans et plus vs 17-30 ans	925349.5	2.420803e-46	9.683213e-46	True

Toutes les tranches d'âge sont significativement différentes de toutes les autres, en terme de fréquence d'achat

5.4 L'âge et le panier moyen

tranche_age20	effectif	moyenne	mediane	q1	q3	ecart_type	ecart_interquartile
17-30 ans	2080	69.68	67.02	54.02	82.36	24.30	28.34
31-50 ans	3410	34.88	32.17	28.79	37.04	11.59	8.25
51-70 ans	2457	26.96	24.57	20.81	30.42	10.23	9.61
71 ans et plus	649	26.49	24.08	20.94	29.87	9.16	8.93

5.4 L'âge et le panier moyen



Pour choisir le test approprié, voyons si les valeurs sont normalement distribué à l'intérieur de chaque tranche:

Test de **Shapiro-wilis**
17-30 ans :
W = 0.9330, p-value = 1.375565e-29
31-50 ans :
W = 0.7409, p-value = 1.327581e-58
51-70 ans :
W = 0.8195, p-value = 2.933070e-46
71 ans et plus :
W = 0.8632, p-value = 2.453738e-23

L'hypothèse de normalité est rejetée partout. Nous ne pouvons pas utiliser le test ANOVA

5.4 L'âge et le panier moyen

Test non-paramétrique: **Kruskal- Wallis**

H0 : La distribution du panier moyen est identique dans toutes les tranches d’âge.
H1 : La distribution du panier moyen diffère pour au moins une tranche d’âge.

Kruskal-Wallis : H = 4714.3139
P-value = 0.000000e+00

H0 est rejeté: les paniers moyens ne sont pas identiques dans toutes les tranches d'Age

Epsilon carré : 0.5483

La taille de l’effet est très importante

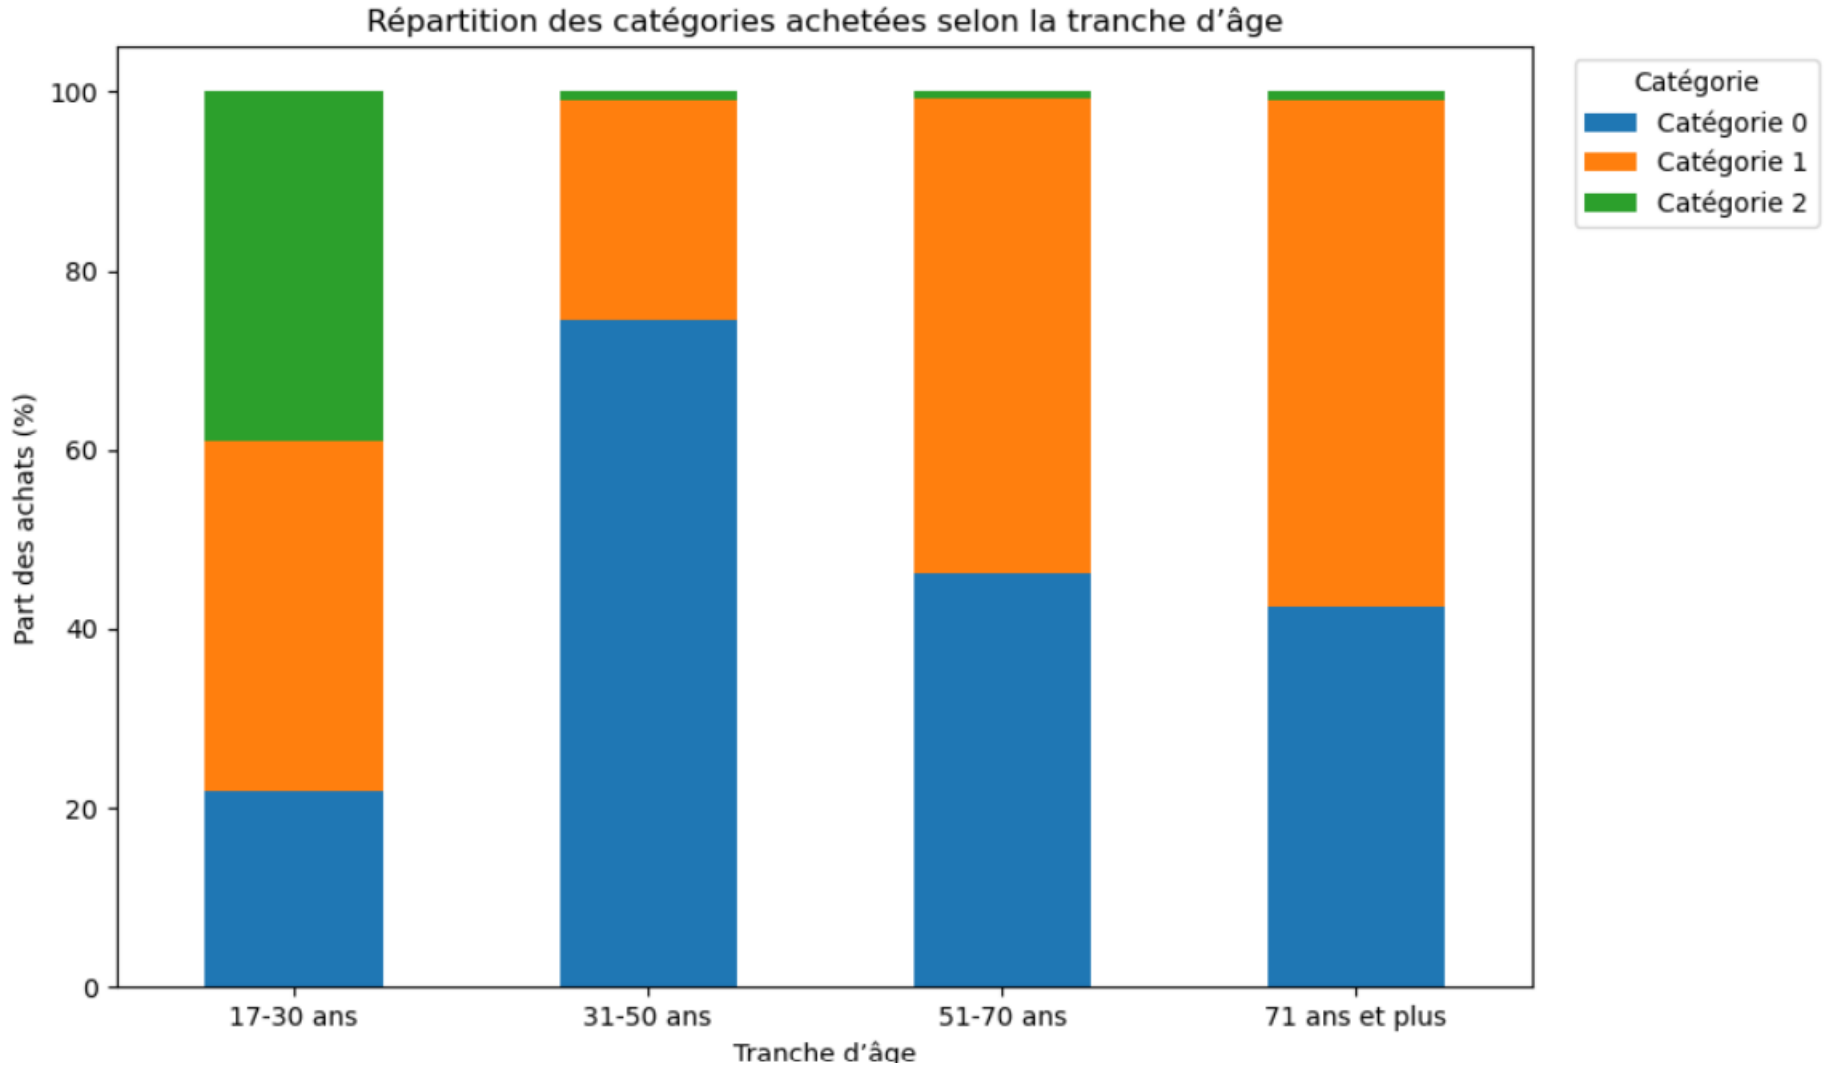
5.4 L'âge et le panier moyen

Test de différence de médiane entre les tranches d'age.
H0: le médiane du groupe 1 est différent du médiane de groupe 2
H1: il n'y a pas de différence entre les médiane des deux groupes

	comparaison	mediane_groupe_1	mediane_groupe_2	difference_medianes	p_value_corrigee	effet_r	significatif
0	17-30 ans vs 31-50 ans	67.015	32.175	34.840	0.0000	0.8636	True
1	17-30 ans vs 51-70 ans	67.015	24.570	42.445	0.0000	0.9336	True
2	17-30 ans vs 71 ans et plus	67.015	24.080	42.935	0.0000	0.9411	True
3	31-50 ans vs 51-70 ans	32.175	24.570	7.605	0.0000	0.5387	True
4	31-50 ans vs 71 ans et plus	32.175	24.080	8.095	0.0000	0.5669	True
5	51-70 ans vs 71 ans et plus	24.570	24.080	0.490	0.3807	0.0223	False

Le test de Kruskal-Wallis met en évidence une différence importante du panier moyen selon la tranche d'âge, avec une taille d'effet élevée (ε2=0,548). Les comparaisons post-hoc de Mann-Whitney, corrigées selon la méthode de Holm, montrent que les 17–30 ans ont un panier médian significativement supérieur à toutes les autres tranches. Les 31–50 ans présentent également un panier supérieur à celui des clients de 51 ans et plus. En revanche, aucune différence significative n'est observée entre les 51–70 ans et les 71 ans et plus. Le panier moyen semble donc diminuer fortement avec les grandes classes d'âge, puis se stabiliser à partir de 51 ans.

5.5 Age et catégorie de livre



5.5 Age et catégorie de livre

H0 : la tranche d'âge et la catégorie du livre acheté sont indépendantes.
H1 : la tranche d'âge et la catégorie du livre acheté sont associées.

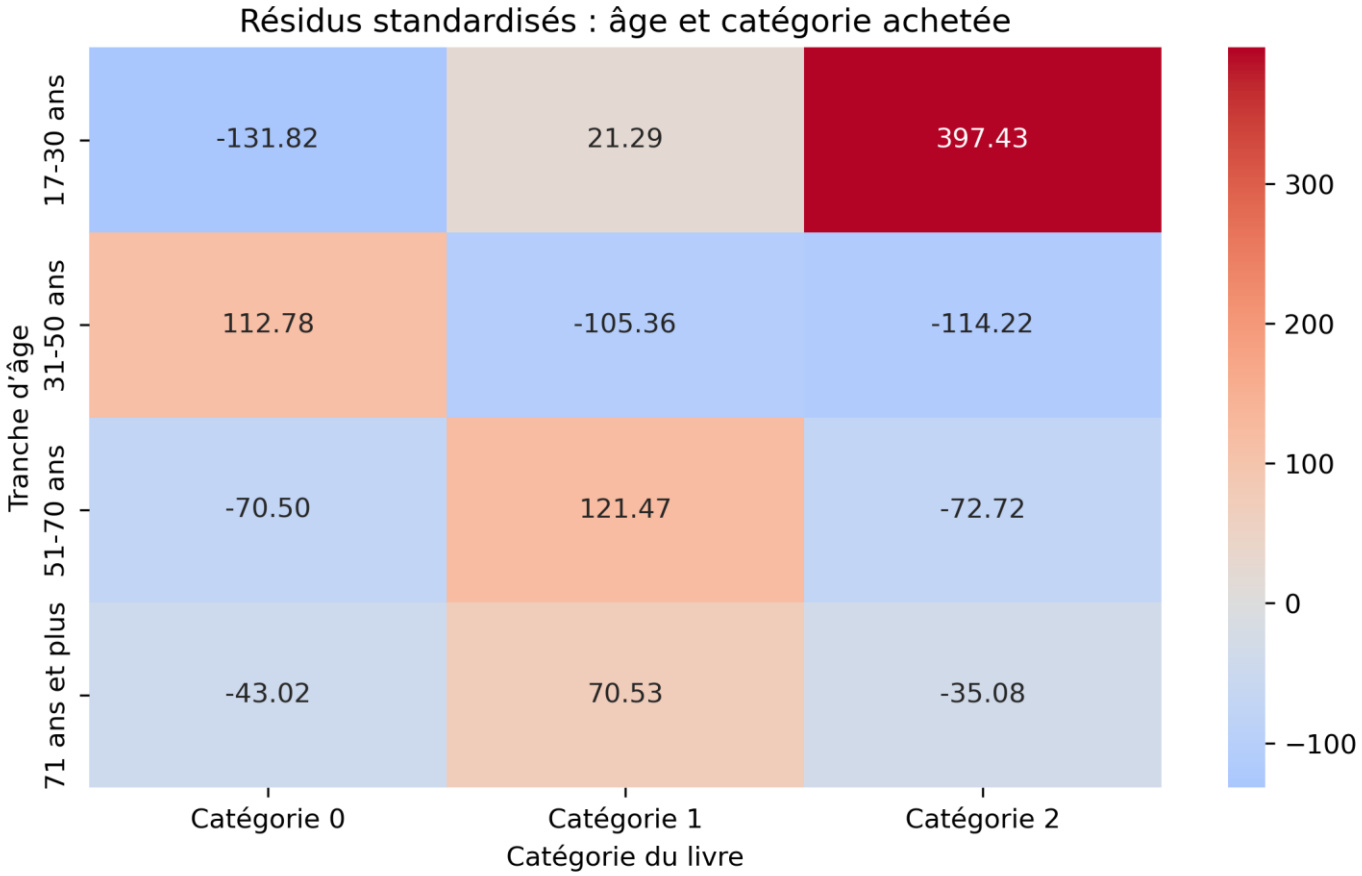
Table des pourcentage d'achat entre différentes catégories pour chaque tranche

tranche_age20	Catégorie 0	Catégorie 1	Catégorie 2
17-30 ans	21.88	39.13	38.99
31-50 ans	74.53	24.50	0.97
51-70 ans	46.20	52.95	0.85
71 ans et plus	42.51	56.63	0.87

Tranche d'age: qualitative ordonnée, avec quatre groupes
Catégorie: qualitative, avec les catégories 0, 1 et 2.

Test **khi^2 d'indépendance**

5.5 Age et catégorie de livre



Statistique du khi^2 : 245715.8178
Degrés de liberté : 6
P-value : 0.000000e+00

Rejet de H0 : la catégorie achetée est associée à la tranche d'âge

V de Cramér : 0.4379

Association modérée à forte

6- Conclusion

Les jeunes (17 à 30):

- Achètent moins fréquemment
- Mais la valeur de leur panier moyen est plus élevé
- Sont des principaux acheteurs du catégorie 2 (nettement plus cher)

Un client de 31-50 ans génère en moyenne plus de chiffre d’affaire que les autres catégories
Suivi par les 17-30 ans