# ONCFM

l’Organisation nationale de lutte contre le faux-monnayage



# Objectif et démarches

## Objectif

Mettre en place une modélisation pour identifier les faux billets grâce à leurs caractéristiques dimensionnelles.

## Démarches

Nettoyage des données (Gestion des valeurs manquante)

Exploration (analyses univariées, matrice de corrélation)

Modèles prédictifs:

Régression Logistique

K-means

Validation du modèle

Création de la fonction de prédiction

Comparaison et choix de meilleure algorithme prédictive

Production de l’application

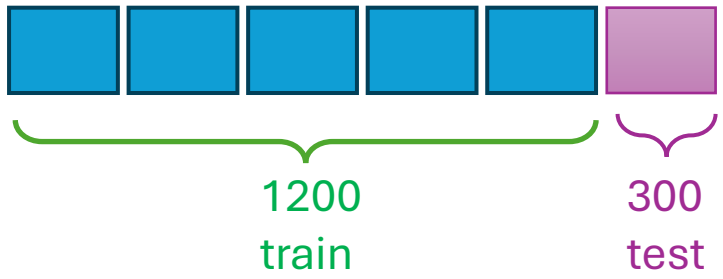
# Données

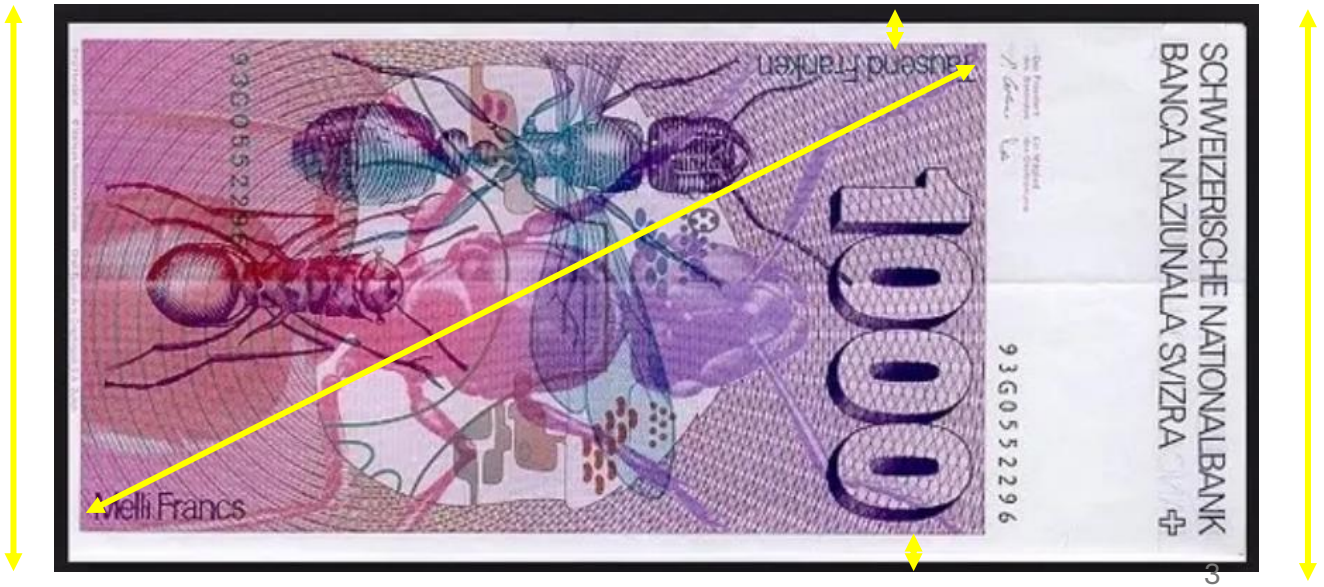
Variable expliquée

Variables explicatives

| | is_genuine | diagonal | height_left | height_right | margin_low | margin_up | length |
|---|---|---|---|---|---|---|---|
| **0** | True | 171.81 | 104.86 | 104.95 | 4.52 | 2.89 | 112.83 |
| **1** | True | 171.46 | 103.36 | 103.66 | 3.77 | 2.99 | 113.09 |
| **2** | True | 172.69 | 104.48 | 103.50 | 4.40 | 2.94 | 113.16 |

1500 données



# Données

Répartir les données aux hasard dans deux groupes
80% => train
20% => test

Mais on veux avoir la même proportion de faux billets dans les deux groupes.

Ensemble :
1000 vrai
500 faux

Train :
800 vrai
400 faux

Test :
200 vrai
100 faux

Valeurs manquantes:

« Margin_low » manque pour 37 billets :
25 pour tain;  12 pour test

Substitué par le médian (préférable à la moyenne car peu sensible à des valeurs extrême)

Seulement calculé à partir de train
Substitué dans train + test

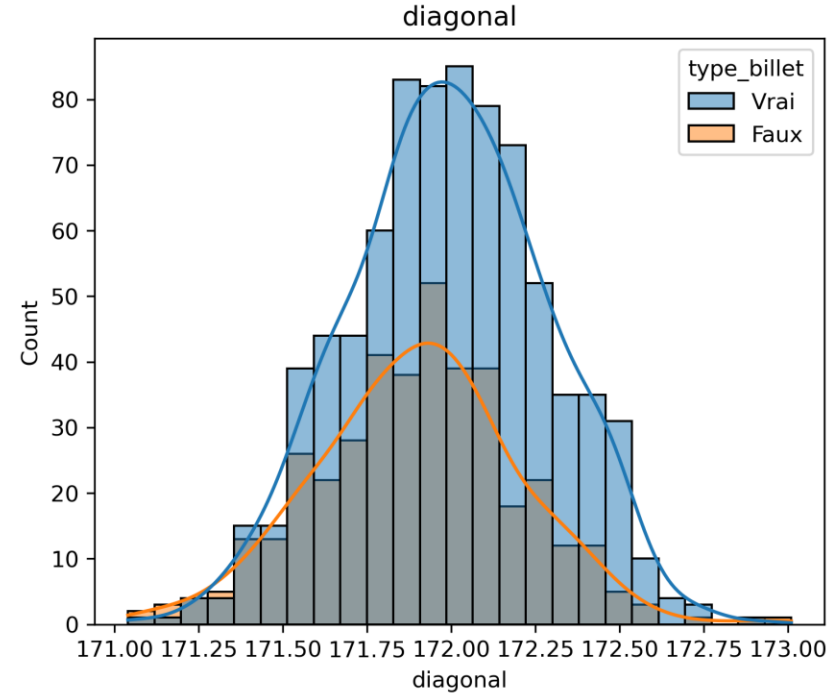
# Exploration des données

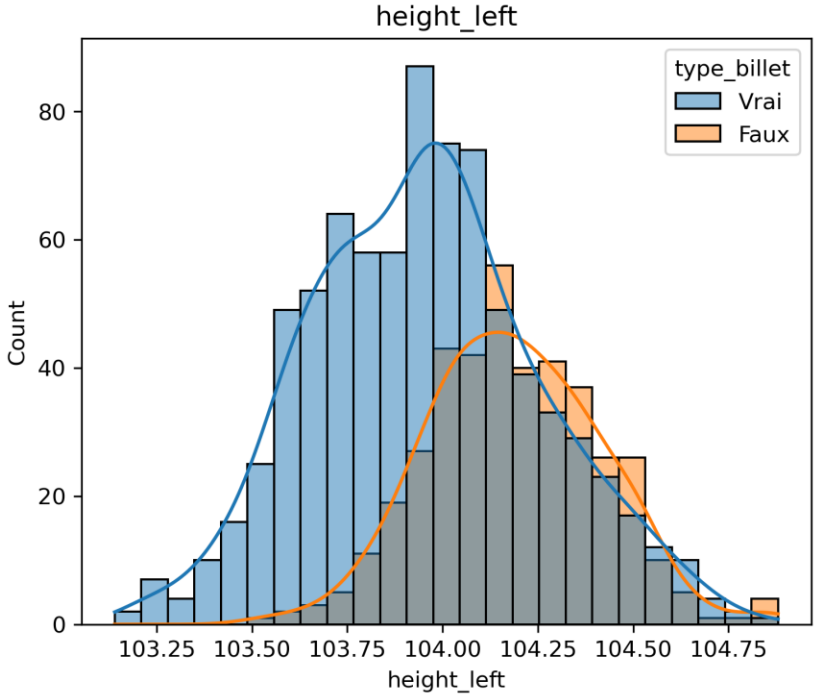
Mesures moyennes en fonction de type de billet

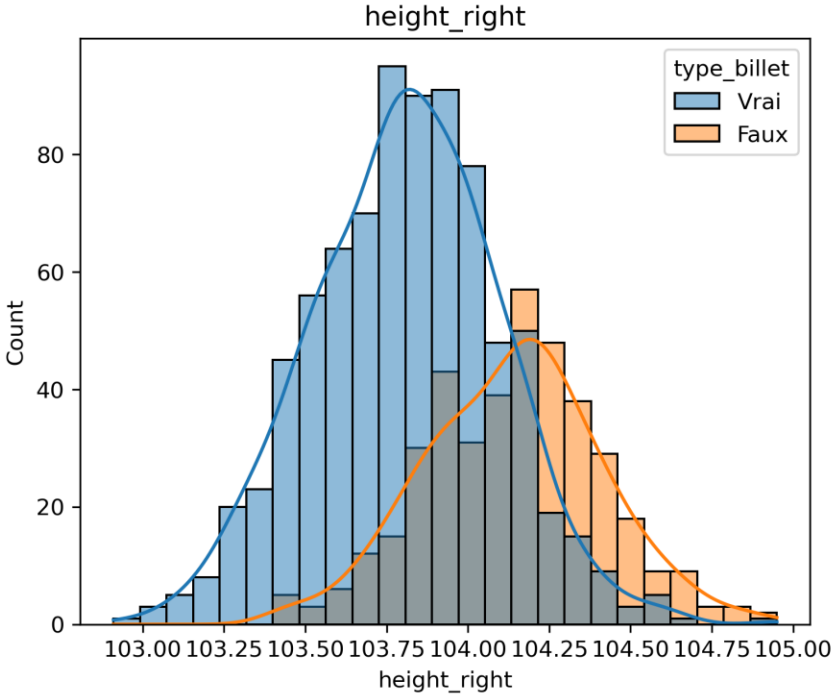
| | diagonal | height_left | height_right | margin_low | margin_up | length |
|---|---|---|---|---|---|---|
| **Faux** | 171.899 | 104.187 | 104.140 | 5.201 | 3.350 | 111.617 |
| **Vrai** | 171.990 | 103.954 | 103.809 | 4.131 | 3.053 | 113.194 |

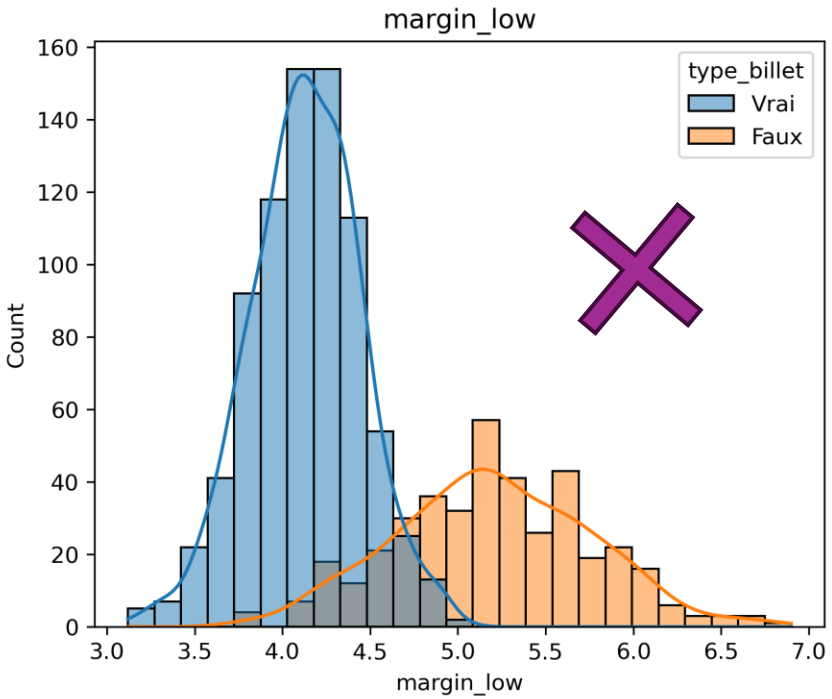
Très proches

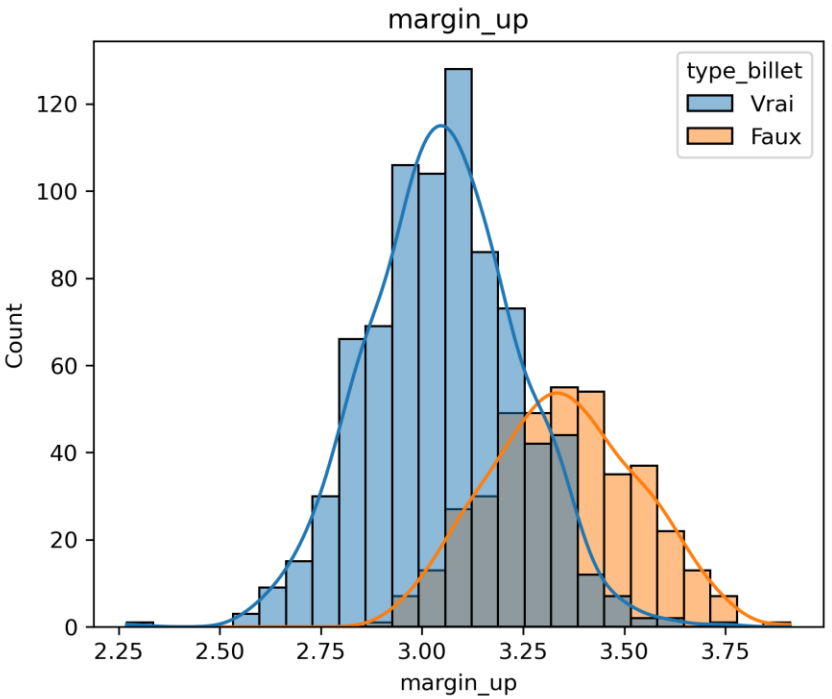
Plus discriminants

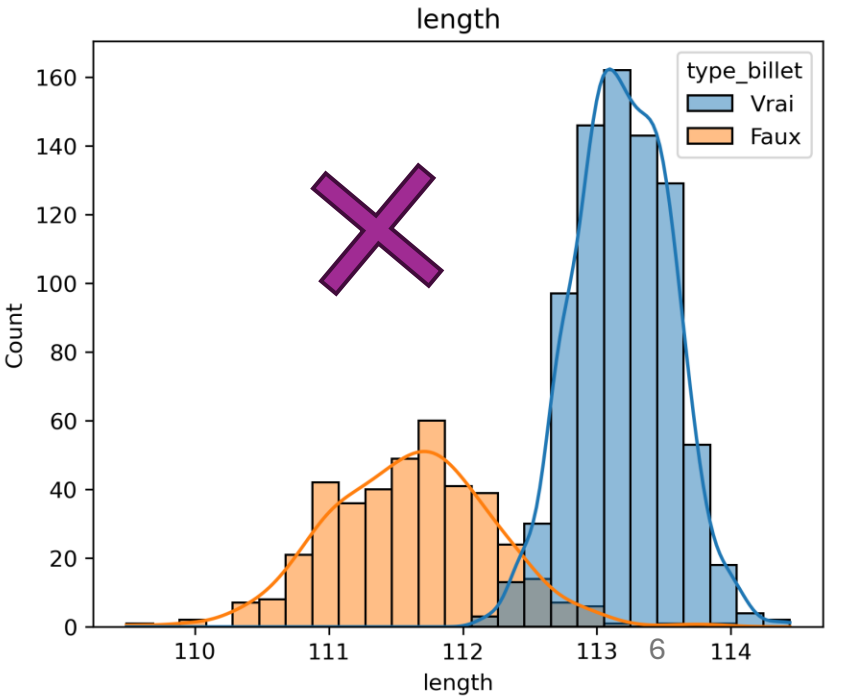

diagonal
type_billet
Vrai
Faux
Count
diagonal


height_left
type_billet
Vrai
Faux
Count
height_left


height_right
type_billet
Vrai
Faux
Count
height_right

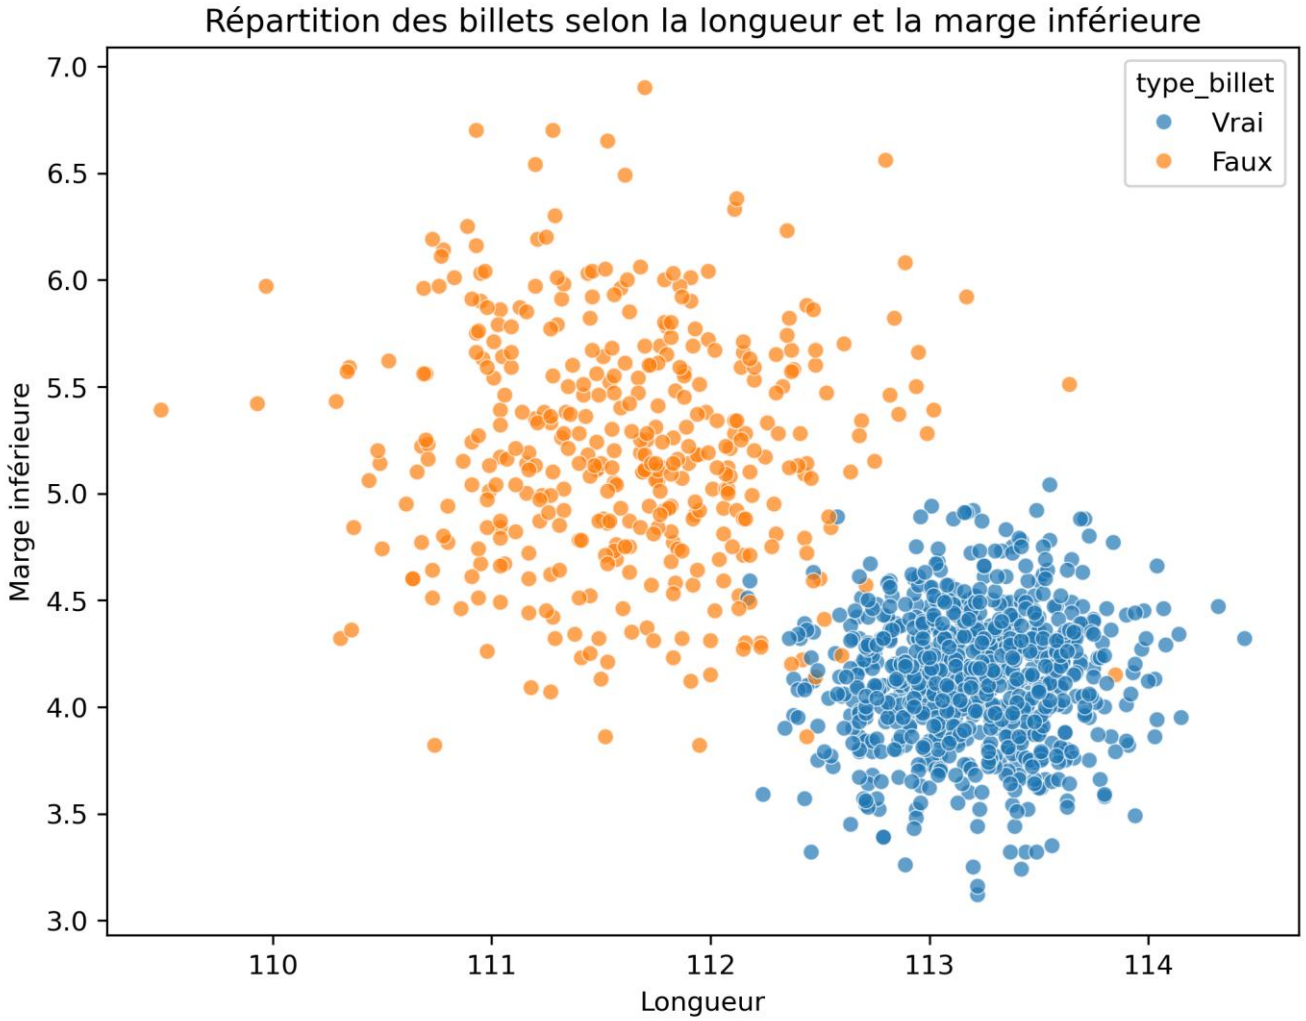

margin_low
type_billet
Vrai
Faux
Count
margin_low


margin_up
type_billet
Vrai
Faux
Count
margin_up


length
type_billet
Vrai
Faux
Count
length

# Exploration des données

Deux dimensions: margin_low et lenght: différence assez nette entre vrais et faux billets



# Précision et spécificité des prédictions

La matrice de confusion nous dit à quel point notre algorithme a bien fonctionné sur les données de test.

| | | Prédictions | |
|---|---|---|---|
| | | vrai | faux |
| Nature de billet | vrai | True negative | False positive |
| | faux | False negative | True positive |

**Rappel = Sensibilité = TP / (TP + FN)**

Parmi tous les **vrais positifs réels**, quelle proportion le modèle a-t-il correctement détectée ?

**Précision = TP / (TP + FP)**

Parmi tout ce que le modèle **a prédit positif**, quelle proportion est réellement positive ?

**Spécificité = TN / (TN + FP)**

Parmi tous les **négatifs réels**, quelle proportion le modèle a-t-il correctement reconnue ?

# Modèles de prédiction : Logistique

**Régression Logistique:**
Quelle est la probabilité qu'un événement binaire arrive, en tenant compte de plusieurs facteurs en même temps ? »

Régression linéaire : $y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k$

Y sera une valeur continue. Mais nous voulons une probabilité

Le modèle opère une transformation logit:

$$y = log\left(\frac{p}{1-p}\right)$$

**Prédiction :**

Si $p < 0{,}5$ => catégorie 0 (billet authentique)
Si $p \geq 0{,}5$ => catégorie 1 (billet faux)

```
Confusion matrix:
[[199   1]
 [  2  98]]

Classification report:
              precision    recall  f1-score   support

     genuine       0.99      0.99      0.99       200
        fake       0.99      0.98      0.98       100

    accuracy                           0.99       300
   macro avg       0.99      0.99      0.99       300
weighted avg       0.99      0.99      0.99       300
```

# Modèles de prédiction : k-means

**La méthode K-means** permet de rassembler les individus qui ont des caractéristiques semblables dans un nombre prédéfini de cluster

Ici: rassembler les billets dans **2 clusters** en fonctions de leurs dimensions.

Résultats sur 1200 billets:

Cluster 0 : 394 billets
Cluster 1 : 806 billet

Attribuer des étiquettes:
Cluster 0 = faux billets
Cluster 1 = vrais billets

```
Confusion matrix:
[[198   2]
 [  2  98]]

Classification report:
              precision    recall  f1-score   support

     genuine       0.99      0.99      0.99       200
        fake       0.98      0.98      0.98       100

    accuracy                           0.99       300
   macro avg       0.98      0.98      0.98       300
weighted avg       0.99      0.99      0.99       300
```

# Modèles de prédiction : KNN

**K-Nearest Neighbors (**les K plus proches voisins)

Supervisé

pour prédire si un nouveau billet est genuine ou fake, le modèle regarde dans les billets d'entraînement quels sont les **K billets qui lui ressemblent le plus** selon leurs six dimensions géométriques.

Données centrées réduites: car le modèle se base sur les distance – sensible aux échelles.

k=5
valeur de départ classique
assez petite pour rester locale et impaire pour éviter plus facilement les égalités lors du vote

```
Confusion matrix:
[[198   2]
 [  3  97]]

Classification report:
              precision    recall  f1-score   support

     genuine       0.99      0.99      0.99       200
        fake       0.98      0.97      0.97       100

    accuracy                           0.98       300
   macro avg       0.98      0.98      0.98       300
weighted avg       0.98      0.98      0.98       300
```

# Modèles de prédiction : Random Forest

On peut utiliser les données initiales sans standardiser.

Supervisé

Un **arbre de décision** = une suite de questions pour arriver à une prédiction.
**Random Forest** = beaucoup d'arbres différents.
Pour chaque nouvelle donnée: Les arbres votent, et la classe majoritaire gagne.

Choix de nombre d'arbre: 100 (choix classique)

```
Accuracy: 0.99

Confusion matrix:
[[199   1]
 [  2  98]]

Classification report:
              precision    recall  f1-score   support

     genuine       0.99      0.99      0.99       200
        fake       0.99      0.98      0.98       100

    accuracy                           0.99       300
   macro avg       0.99      0.99      0.99       300
weighted avg       0.99      0.99      0.99       300
```

# Comparer la performance des 4 modèles

| Log | vrai | faux |
|---|---|---|
| vrai | 199 | 1 |
| faux | 2 | 98 |

Rappel = **98**%

Précision = **99**%

| KNN | vrai | faux |
|---|---|---|
| vrai | 198 | 2 |
| faux | 3 | 97 |

Rappel = **97**%

Précision = **98**%

| K mean | vrai | faux |
|---|---|---|
| vrai | 198 | 2 |
| faux | 2 | 98 |

Rappel = **98**%

Précision = **98**%

| RF | vrai | faux |
|---|---|---|
| vrai | 199 | 1 |
| faux | 2 | 98 |

Rappel = **98**%

Précision = **99**%

# Régression Logistique vs Random Forest

Pour les 3 billets problématiques

| | Actual | pred_log | proba_log | pred_rf | proba_rf |
|---|---|---|---|---|---|
| **728** | 0 | 1 | 0.924923 | 1 | 0.87 |
| **1190** | 1 | 0 | 0.478142 | 0 | 0.26 |
| **1160** | 1 | 0 | 0.323895 | 0 | 0.26 |

**Faux négatifs**

**Choix final:**

**Modèle de régression Logistique**